

分类号：TP391
密 级：公 开
单位代码：10878
学 号：202233105007



安徽建筑大学
ANHUI JIANZHU UNIVERSITY

硕 士 学 位 论 文

论 文 题 目 基于大模型的智慧医疗问答
研究与应用
申请学位类别 工学硕士
一级学科名称 控制科学与工程
二级学科名称 模式识别与智能系统
作 者 姓 名 储继晴
导 师 姓 名 黄河
完 成 时 间 2025 年 5 月

基于大模型的智慧医疗问答研究与应用

Research and Application of Intelligent Medical Question Answering based on Large Language Model

申请学位类别	工学硕士
一级学科名称	控制科学与工程
二级学科名称	模式识别与智能系统
作者姓名	储继晴
导师姓名	黄河
完成时间	2025 年 5 月

摘 要

近年来,以 Transformer 架构为核心的大规模预训练语言模型在自然语言处理领域取得突破性进展。在医疗健康领域,这类模型因其强大的语义理解与知识推理能力,被视为推动智慧医疗发展的关键技术。然而,医疗场景的特殊性对通用大型语言模型提出严峻挑战:专业术语的复杂性导致的语义鸿沟、医学知识更新滞后引发的模型幻觉问题,以及诊疗场景中对安全性、可靠性和可解释性的严格要求。因此,本文选择通用大型语言模型作为基础模型,开展了基于大型语言模型的智慧医疗问答研究与应用,主要内容如下:

在模型优化层面,针对大型语言模型在医疗场景中存在的训练成本高、知识不全面和回答冗余的问题,本文使用参数高效微调技术和检索增强生成技术为通用大型语言模型 ChatGLM3-6B 注入医学知识,并引入级联去重机制去除模型生成回答中的冗余信息,使其更适合医疗领域。首先使用公开医疗对话数据集 DISC-Med-SFT 对通用大型语言模型 ChatGLM3-6B 进行微调;之后,基于对话数据和临床医学指南构建医学知识库为模型提供准确的知识来源;最后,针对大型语言模型生成的回答进行级联去重,使其生成流畅、可靠的回答。实验结果表明,Med-Chat 与基线模型 ChatGLM3-6B 相比,在 BLEU 指标提升了 1.46,在 F1-1、F1-2 指标上分别提高了 3.04 和 4.79。利用专门的医疗数据和医学知识训练优化后的 Med-Chat,减少了通用大型语言模型在医学术语、诊断描述上的误解以及生成误导性或不专业建议的情况,在医学问答任务中具有显著的优势。

在模型应用层面,本文开发了基于大型语言模型的智能医疗问答系统,通过在本地部署大型语言模型并实现各功能模块的分区管理,保障了医疗数据的隐私性和安全性。该系统由健康问答、智能客服和门诊导诊三大核心模块组成:健康问答模块通过利用大模型的自然语言处理能力与医学知识库提供的医学知识,为用户提供个性化的健康咨询服务;智能客服模块支持全天候在线服务,可以随时解答用户关于科室位置、就诊流程和药物信息等方面的常见问题;门诊导诊模块利用智能体技术,通过分析用户的症状与需求,为其推荐合适的科室或医生,显著提升了患者的就医效率与体验感。

图 [32] 表 [10] 参 [78]

关键词: LoRA 微调; 向量知识库; 级联去重; 医疗问答

分类号: TP391

Abstract

In recent years, large-scale pre-trained language models with Transformer architecture as the core have made breakthrough progress in the field of natural language processing. In the field of medical health, such models are regarded as key technologies to promote the development of smart medicine due to their powerful semantic understanding and knowledge reasoning capabilities. However, the particularity of medical scenarios poses severe challenges to general large language models: the complexity of professional terms leads to semantic gaps, the hallucination problem caused by the lag in medical knowledge updates, and the strict requirements for security and interpretability in diagnosis and treatment scenarios. For this reason, this article selects a general large language model as the basic model. In order to meet its application requirements in the field of smart medical question answering, it conducts research and application of smart medical question answering based on the large language model. The main contents are as follows:

In terms of model optimization, in order to address the problems of high training cost, incomplete knowledge and redundant answers of large language models in medical scenarios, this paper uses efficient parameter fine-tuning technology and retrieval augmented generation technology to inject medical knowledge into the general large language model ChatGLM3-6B, and introduces a cascade deduplication mechanism to remove redundant information in the answers generated by the model, making it more suitable for the medical field. First, the general large language model ChatGLM3-6B is fine-tuned using the public medical dialogue dataset DISC-Med-SFT; then, a medical knowledge database is built based on dialogue data and clinical medical guidelines to provide an accurate source of knowledge for the model; finally, cascade deduplication is performed on the answers generated by the large language model to generate fluent and reliable answers. Experimental results show that compared with the baseline model ChatGLM3-6B, Med-Chat improves the BLEU index by 1.46, and improves the F1-1 and F1-2 indicators by 3.04 and 4.79 respectively. Med-Chat, which is optimized by training with specialized medical data and medical knowledge, reduces the misunderstanding of medical terms and diagnostic descriptions by large language models, as well as the generation of misleading or unprofessional advice, and has significant advantages in medical question-answering tasks.

At the model application level, this paper develops an intelligent medical question-answering system based on the large language model. The system ensures the privacy and security of medical data through the large language model used in the local deployment system and the partition management of each functional module. The system consists of three core modules: health question-answering, intelligent customer service, and outpatient guidance. The health question-answering module provides users with personalized health consulting services by utilizing the natural language processing capabilities of the large language model and the medical knowledge provided by the medical knowledge database; the intelligent customer service module facilitates round-the-clock online support and is capable of responding to users' frequent inquiries regarding departmental positions, medical processes, and medication details whenever needed; the outpatient guidance module employs smart agent technology to assess user symptoms and needs, recommending appropriate departments or doctors, thereby greatly enhancing patient care efficiency and overall experience.

Figure [32] table [10] reference [78]

KeyWords: LoRA fine-tuning; vector knowledge base; cascade deduplication; medical questions and answers

Chinese books catalog: TP391

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 国内研究现状.....	2
1.2.2 国外研究现状.....	4
1.3 论文研究内容.....	5
1.4 论文组织结构.....	6
第二章 基本理论与相关技术	7
2.1 Transformer 模型架构.....	7
2.1.1 整体框架.....	8
2.1.2 编码器.....	9
2.1.3 解码器.....	12
2.2 通用大语言模型.....	15
2.2.1 ChatGPT.....	15
2.2.2 ChatGLM 系列	16
2.2.3 DeepSeek.....	16
2.2.4 参数高效微调技术.....	17
2.3 RAG 技术	18
2.4 智能体.....	19
2.5 本章小结.....	20
第三章 基于中文医疗对话数据微调的轻问诊模型	21
3.1 引言.....	21
3.2 LoRA 微调.....	22
3.3 外接向量知识库.....	24
3.3.1 构建向量知识库.....	24
3.3.2 RAG 技术接入	25
3.4 级联去重.....	27
3.5 实验.....	28
3.5.1 数据集介绍.....	28
3.5.2 实验设置.....	29
3.5.3 评价指标.....	31
3.5.4 实验结果.....	32
3.5.5 消融实验.....	34
3.5.6 案例分析.....	35

3.6 本章小结.....	37
第四章 基于大模型的智慧医疗问答应用设计与实现	39
4.1 引言.....	39
4.2 系统架构设计.....	40
4.2.1 总体架构.....	40
4.2.2 功能模块设计.....	41
4.3 构建常见疾病医学知识库	43
4.3.1 数据收集与处理.....	43
4.3.2 知识库的更新与维护.....	44
4.4 系统模块功能实现.....	45
4.4.1 健康问答功能模块.....	46
4.4.2 智能客服功能模块.....	49
4.4.3 门诊导诊功能模块.....	49
4.5 本章小结.....	50
第五章 总结与展望	52
5.1 总结.....	52
5.2 展望.....	52
参考文献.....	54

第一章 绪论

1.1 研究背景与意义

健康作为人类生存与发展的基石，既是实现个体全面发展的核心要素，也是推动社会经济发展的先决条件，更是衡量国家繁荣与民族兴盛的重要标尺。在人口老龄化进程加速与慢性病发病率持续攀升的双重挑战下，伴随经济水平的显著提升，国民健康意识呈现出系统性增强态势。值得关注的是，在数字技术革命推动下，现代医疗健康服务已突破传统线下诊疗模式，呈现出显著的“互联网+”特征。因此，在去线下面诊前，越来越多的人选择，先根据自身的身体状况在互联网上检索相关情况，了解相关病症知识。而在互联网上“自诊”时，需要从繁杂的互联网数据中寻找导致不适的病因。传统的搜索引擎主要依赖关键词匹配进行信息检索，并未深入到语义层面进行理解与分析，搜索结果通常以网页链接形式返回^[1]，要求用户自己进一步筛选和辨识有用信息，增加了用户的“自诊”风险。这种现象导致医疗健康问答相关的应用需求场景大量涌现。

Transformer 模型^[2]的诞生使自然语言处理从监督学习和半监督学习阶段进入“预训练+微调”阶段。作为人工智能领域的重要突破，ChatGPT 的出现让研究者们认识到大型语言模型（Large Language Model, LLM）强大的语言处理能力和泛化能力^[3]，也让许多人开启了与人工智能的第一次“亲密接触”。随后，国内外各大高校、研究院所和高新企业也相继发布了新的大型语言模型，比如 Meta AI 开源的 LLaMA^[4-5]、清华大学发布的 ChatGLM 系列^[6]、百川智能公开的 Baichuan 系列^[7]等。由于大型语言模型可以实现有问必答的快速响应，提供清晰明了的思考过程，这为医疗行业的智慧化转型提供了一种新的智能支持，同时，也为实现医疗服务的智能化与精准化转型提供了坚实的技术保障和创新动力。比如基于大语言模型构建的医学智能问答系统可以生成直接、准确的回答，无需用户自己筛选和辨别有用信息，用户的体验感和检索效率得到显著提升^[8]。虽然大型语言模型表现出了卓越的性能，但通用大型语言模型在落地产业场景时，往往无法与具体业务精准结合，导致“水土不服”。在此背景下，专为产业细分需求打造的垂直模型应运而生，成为大型语言模型技术落地产业应用的新趋势。应用在医疗健康领域的垂直模型通常由对大型语言模型预训练或微调获得^[9]，通过收集含有医疗专业知识的文档、整合相关权威材料，将其作为语料库对大型语言模型进行预训练，从而得到具备大量医学知识背景的医学大型语言模型；或者收集相关医疗数据，构建微调数据集，将现有的通用大型语言模型作为基模型，对其进行微调，提升大型语言模型在医疗健康领域上的流畅度和可信度，使其具备在医疗健康场

景下应用的能力。

医学大型语言模型的发展正在为智慧医院的建设带来革命性变革。这些模型具备强大的多轮对话和多模态处理能力，将推动医院服务从传统的点击式操作向自然对话式交互转变。患者、医护人员和管理者都能通过简单的对话与系统互动，提出各种个性化问题，获得准确可靠的答复。与当前分散的智能导诊、用药指导等单一功能应用不同，未来基于大模型的智慧就医应用将整合多项服务，为患者提供从问诊、分诊到就医咨询、用药指导的一站式服务，并能根据患者的个人情况提供个性化的健康管理建议。在诊疗方面，部分人工智能应用（如肺结节辅助诊断系统）仍局限于特定任务，无法实现深度的人机交互，未来的智慧医疗将借助大型语言模型实现全方位的人机协同诊疗^[10]。通过分析患者的多维度数据，大模型可以帮助医生更早发现疾病征兆，提供精准的诊断分析、治疗建议和预后预测，实现医生与人工智能的深度协作，共同提升诊疗水平。这种变革将使医疗服务更加智能化、个性化和高效化，为患者带来更好的就医体验。

虽然大型语言模型在医疗健康领域展现了广阔的应用前景，但其存在的局限性也不容忽视。一方面，模型有时会产生与事实不符的回答，即所谓的幻觉现象，这在需要高度专业性和准确性的医疗场景中尤为危险，可能导致严重的临床决策错误。另一方面，训练这些大型语言模型需要投入巨大的计算资源，其高昂的成本不仅影响了模型在医院的实际部署，也制约了相关研究的深入开展。为应对这些问题，本文研究了如何将大型语言模型应用到医疗问答场景下，并构建了一个基于大型语言模型的智慧医疗问答系统。

1.2 国内外研究现状

在医疗健康领域，大型语言模型展现出了极大的应用潜力。通过利用医学数据进行预训练或微调，大型语言模型可以初步理解医学知识，能够在医疗研究、临床诊断、药物开发等各个方面为人类提供服务，这对于改善医疗服务质量、提升医疗健康水平具有重要的实践意义。随着医疗健康数据的不断积累和人工智能技术的迅速发展，越来越多的研究者将目光移向医学大型语言模型。

1.2.1 国内研究现状

近年来，在国家大力推动“人工智能+医疗”深度融合的宏观背景下，医疗大型语言模型逐渐在国内的大型语言模型应用研究中占据了一席之地。Transformer 架构也为医疗大型语言模型的发展带来了肥沃的技术土壤，医联于 2023 年 5 月正式发布其自主研发的基于 Transformer 架构的医疗大型语言模型

MedGPT。该模型分别使用了超过 20 亿的医学文本数据和 800 万条的高质量结构化临床诊疗数据进行预训练和微调，并投入了超过 100 名医生参与人工反馈监督微调训练，致力于在真实医疗场景中发挥诊疗价值，实现从疾病预防、诊断、治疗、康复的全流程智能化诊疗能力^[11]。随着大型语言模型开源版本的公布，基于通用大型语言模型微调构建的医疗大语言模型也层出不穷。首个中文中医药大型语言模型 ShenNong-TCM 提出以实体为中心的自指令方法，即围绕中医药领域中的核心实体以及各种不同的意图场景，进行指令的生成^[12]。然后通过使用中医药指令数据集 ShenNong_TCM_Dataset 对中文 LLaMA-7b 模型进行 LoRA 微调，使其在回复中医药相关问题方面获得明显提升。Wang 等人通过医学知识图谱^[13]和 GPT-3.5 的 API 构建了中文医学指令数据集，并在此基础上分别对 LLaMA、ChatGLM 模型进行指令微调，生成了医学大型语言模型 Ben Tsao 和 Med-ChatGLM^[14]。薛栋等人研发的孙思邈中文医疗大模型（Sunsimiao）^[15]，通过融合各类医疗文献及教材、多科室诊断数据、海量医疗问诊对话、医学知识问答、病例分析等中文医疗数据，构建微调数据集，然后对基模型 Baichuan-7B 进行微调，致力于构建一个安全、可靠、普惠的中文医疗大型语言模型。QiZhenGPT^[16]依托启真医学知识库构建中文医学指令数据集，并基于此分别对 Chinese-LLaMA-Plus-7B^[17]、CaMA-13B、ChatGLM-6B 模型进行指令精调，大幅提高了模型在中文医疗场景下的适配度，显著提升了药品知识问答的准确性，研发者们计划逐步优化疾病、手术、检验等方面的问答效果，并针对医患问答、病历自动生成等应用展开拓展。此外，基于 QiZhenGPT 研发的智慧医疗助手 MedCopilot 已在浙江大学第二附属医院正式上线使用。基于主动健康的主动性、预防性、精确性、个性化、共建共享、自律性六大特征，华南理工大学未来技术学院和广东省数字孪生人重点实验室联合开源了中文领域生活空间主动健康大型语言模型基座 ProactiveHealthGPT，该模型包括经过千万规模中文健康对话数据指令微调的生活空间健康大型语言模型扁鹊（BianQue）和经过百万规模心理咨询领域中文长文本指令与多轮共情对话数据联合指令微调的心理健康大型语言模型灵心（SoulChat）。其中，BianQue 基于扁鹊健康大数据集 BianQueCorpus 在 ChatGLM-6B 上进行全量参数的指令微调，对模型的建议和知识查询能力进行了强化^[18]；SoulChat 是使用超过 120 万个样本的单轮与多轮混合的共情对话数据集 SoulChatCorpus 对 ChatGLM-6B 进行全量参数的指令微调生成的心理健康大型语言模型，提高了模型的共情能力、引导用户倾诉能力以及提供合理建议的能力^[19]。来自北京邮电大学的王光宇等人提出了 ClinicalGPT，这是一种专门为临床场景设计和优化的大型语言模型，通过在训练过程中利用广泛且多样的真实数据，例如医疗记录、医学领域知识和医疗网站的多轮对话咨询，ClinicalGPT 可以更好地处

理多项临床任务,优化了大型语言模型在临床场景中的应用^[20]。同时,为了保障模型能够生成可靠、安全、无害的回复,研究者们提出了基于人类反馈的强化学习(Reinforcement Learning from Human Feedback, RLHF)^[21],使大型语言模型与人类交互进行对齐。杨松桦等人发布的中文医学大语言模型 Zhongjing,实现了预训练、有监督微调以及 RLHF 对齐这一完整训练流程,并展现了很好的泛化能力^[22]。此外,该模型利用一个包含大量医生主动提问语句的真实医患多轮对话数据集,提升了模型的主动医疗询问能力。

1.2.2 国外研究现状

随着大型语言模型性能的不不断提升,大型语言模型在医学领域上的发展前景也备受关注。自 Google 于 2018 年推出基于 Encoder-Only 架构的 BERT 模型^[23],该模型迅速成为最广泛使用的自然语言处理(Nature Language Processing, NLP)模型之一,越来越多的研究者开始探索如何将其应用到生物医学领域。Lee 等人专为生物医学文本挖掘任务开发了一个生物医学语言表示模型 BioBERT^[24]。该模型通过收集 PubMed 的论文摘要和 PubMed Central 全文构建医学语料库,然后基于 Google 的 BERT 模型进行再次预训练,并在生物医学领域进行了进一步的微调,使其在处理生物医学文本时表现出色。Huang 等人也基于 BERT 模型提出了可用于临床任务的大型语言模型 ClinicalBERT,该模型从公共重症监护多参数智能监测数据集 MIMIC-III 中随机抽取了 10 万条数据进行预训练,之后再针对具体临床任务进行微调,使其能够通过捕获临床记录中的语义关系来预测患者的复诊率^[25]。Gu 等人以生物医学为例,对特定领域的预训练及其对下游应用的影响进行研究,提出了 PubMedBERT^[26]。该模型通过使用 PubMed 的论文摘要从头开始预训练 BERT 大型语言模型,表明从头开始预训练大型语言模型比持续预训练通用领域大型语言模型可以获得显著的性能,推动了自然语言处理在生物医学领域的发展。BERT 模型在 NLP 任务上的卓越性能,同时也激发了许多其他基于 Transformer 架构的大型语言模型的开发。2019 年,Google 再次推出了与 BERT 模型不同架构的 T5 模型^[27],该模型基于 Transformer 的编码器-解码器架构,将所有的 NLP 任务转成文本到文本(text-to-text)的形式,使得预训练和微调的训练目标一样,同时通过在输入文本前加上任务前缀(task-specified prefix)来指定模型要执行的任务类型。随后, Lu 等人利用临床数据对 T5 模型进行预训练,生成用于处理临床文本生成与总结任务的 ClinicalT5^[28],该模型能够生成详细的临床报告、归纳患者病历,并辅助临床决策。自 GPT-3^[29]出现以来,研究者们开始尝试构建基于解码器架构的自回归语言模型,比如 Google 发布的 PaLM 大语言模型^[30]、Meta AI 开发的 LLaMA 模型^[4]等。鉴于自回归语言模型的强大性能,Google 发布了 PaLM

在医疗领域的微调模型 Med-PaLM^[31]。该模型首先基于原始预训练大语言模型 PaLM 在通用领域上进行指令微调，得到 Flan-PaLM^[32]，然后使用少量示例对 Flan-PaLM 进行指令提示微调，将其与医学领域对齐。虽然 Med-PaLM 是第一个在美国医师执照考试（USMLE）中超过及格分数的模型，但其在 MedQA 数据集上的性能还有着很大的改进空间。之后，Google 为减少这些差距提出了 Med-PaLM2^[33]。该模型使用 PaLM 的改进版本 PaLM2 作为基模型，再利用医学数据集 MultiMedQA 的训练集对其专门进行医疗领域上的微调。为了改进 Med-PaLM2 的推理能力，Google 还基于思维链（Chain-of-thought）和自我一致性（Self-consistency）开发了一种新的提示策略，称为集成精炼（Ensemble refinement, ER）。最终，Med-PaLM2 在 MedQA 数据集上得分达到 86.5%，比 Med-PaLM 提高了 19.3%。随着更易部署的开源大型语言模型 LLaMA 的出现，越来越多的研究者开始探索大型语言模型在医疗领域的应用。Li 等人开发的 ChatDoctor 使用真实的医患对话数据集 HealthCareMagic-100k 微调 LLaMA，提高了其在理解患者需求和提供知情建议方面的能力^[34]。此外，ChatDoctor 还引入了基于维基百科或疾病数据库构建的自导向信息检索机制，允许模型根据检索到的相关信息回答患者的问题，进而提升模型响应的准确性。来自剑桥大学语言技术实验室的 Shu 等人提出了生物医学大型语言模型 Visual Med-Alpaca，该模型基于 LLaMa-7B 模型，使用由 GPT-3.5-Turbo 和人类专家共同策划的指令集进行指令微调，并利用即插即用的视觉模块，实现解释放射图像、处理复杂的临床问诊等各种功能^[35]。

1.3 论文研究内容

基于上述研究背景分析及相关工作介绍，本文主要从下面两个方面展开工作：

（1）基于 ChatGLM3-6B 微调的医疗轻问诊模型。针对大语言模型在医疗场景中存在的训练成本高、知识局限性以及信息冗余等问题，采用了一系列的优化策略：首先，利用中文对话数据对通用大模型 ChatGLM3-6B 进行领域微调，使其具备基础的医学问答能力；其次，基于对话数据集和医学指南等医学文本构建医学知识库，并通过检索增强生成技术将其与微调后的大语言模型结合，提升回答的专业性和准确性；最后，引入级联去重机制，有效去除模型回复中的冗余信息，确保生成的回答简洁流畅且可靠。经过这一系列措施，提升了模型在医疗轻问诊场景中的实用性和性能。

（2）基于大语言模型的智能医疗问答系统。本文设计并实现了一个基于大语言模型的智能医疗问答系统，旨在为医疗问答场景提供高效、精准的医学智能服

务。通过使用本地化模型服务框架作为底层支撑平台，支持 Med-Chat 和 DeepSeek-R1 等模型的动态部署与 GPU 资源优化，从而确保系统的高效运行。同时，系统添加了知识库上传组件，使模型能够调用丰富且准确的医学知识。该系统由三大核心模块组成：健康问答、智能客服和门诊导诊。健康问答模块结合大模型的自然语言处理能力与专业医学知识向量库，为用户提供个性化的健康咨询服务；智能客服模块提供全天候在线支持，高效解答科室位置、就诊流程、药品信息等常见问题；门诊导诊模块利用智能体技术来为患者提供自动化的门诊导诊服务，通过分析用户的症状、病史及需求，并基于这些数据做出推荐，帮助用户找到合适的科室或医生，显著提升了患者的就医效率与体验。该系统的开发为智能医疗问答的应用提供了实践参考。

1.4 论文组织结构

本文共分为五章，各章安排如下：

（1）绪论。本章以大语言模型带来的机遇、医疗大语言模型发展面临的挑战为背景，引出本文的研究目的与意义，然后介绍了医疗大模型的国内外研究现状；最后介绍本文的主要研究内容和组织结构。

（2）基础理论与相关技术。本章主要介绍了当前一些主流的大语言模型和本文提出的中文医疗轻问诊模型的理论基础，包括 Transformer 模型结构、一些通用大语言模型、参数高效微调技术、检索增强生成技术以及智能体，为后续工作提供理论支撑和技术基础。

（3）基于中文医疗对话数据微调的轻问诊模型。本章通过利用中文医疗对话数据集进行微调，结合医学指南等医学文本构建医学知识库，并引入级联去重机制，基于 ChatGLM3-6B 模型构建了中文医疗轻问诊模型 Med-Chat。

（4）基于大模型的智慧医疗问答应用设计与实现。本章开发了基于大模型的智能医疗问答系统，实现了高效能的医学智能服务。通过使用本地化模型服务框架作为底层支撑平台，支持 Med-Chat 和 DeepSeek-R1 等大语言模型的动态部署，并通过添加知识库，为大语言模型具备准确、丰富的医学知识提供了保障，进而开发了健康问答模块和智能客服模块，以满足多样化的医疗服务需求。之后还深入探讨了基于大模型的智能体技术在门诊导诊场景中的应用，通过智能分析用户的症状和需求，为用户推荐合适的就诊科室和相关注意事项。

（5）总结与展望。本章节首先概括了已经解决的针对在医疗问答领域应用大语言模型时的实际问题以及已经完成的主要任务，阐述了该研究的研究亮点，并对基于大模型的智慧问答系统的未来研究工作进行展望。

第二章 基本理论与相关技术

基于编码器架构的 BERT 模型在自然语言处理领域展现了出色的性能，这为更多基于 Transformer 架构的大型语言模型的涌现奠定了基础。这些大型语言模型在自然语言处理任务中表现出了卓越的性能，同时，也让人看到了它们在医疗健康领域的非凡潜力。本章将详细介绍 Transformer 架构以及基于该架构的大型语言模型，并介绍一些将通用大型语言模型应用于医疗领域的技术，如参数高效微调技术和检索增强生成技术（Retrieval Augmented Generation, RAG）。此外，本章还将探讨具备自主决策能力的智能体，为后续基于大型语言模型的智慧医疗问答应用提供理论支持与技术架构。

2.1 Transformer 模型架构

自然语言具有无处不在的歧义性、高度的抽象性、近乎无穷的语义组合性和持续的进化性，理解语言往往需要具有一定的知识和推理等认知能力，这些都为计算机处理自然语言带来了巨大的挑战，使其成为机器难以逾越的鸿沟。在早期研究中，研究者主要进行特征工程，即利用自己的知识手动从原始数据（Raw Data）中去提取简明的特征，比如 n 元语言模型（n-gram Language Models）。随着神经网络时代的到来，研究者们将提取特征的工作交给了神经网络中的隐藏层，出现了许多神经语言模型（Neural Language Models, NLM），比如前馈神经网络语言模型（Feedforward Neural Network Language Models, FFNNLM）^[36]、循环神经网络语言模型（Recurrent Neural Network Language Models, RNNLM）^[37]、长短期记忆网络语言模型（Long Short-Term Memory Language Models, LSTMLM）^[38]等。2017 年 6 月，Google 提出了一种新的神经网络模型 Transformer，这是第一个完全摒弃卷积神经网络（Convolutional Neural Network, CNN）、循环神经网络（Recurrent Neural Network, RNN），用注意力（Attention）机制当作特征提取器进行从序列到序列（Sequence to Sequence, Seq2seq）训练的模型架构，该模型主要由编码器（Encoder）和解码器（Decoder）组成。此后，陆续出现了三种 Transformer 架构变体，分别是以 Transformer 的编码器为主的全编码器（Encoder-Only）架构、以 Transformer 的解码器为主的全解码器（Decoder-Only）架构以及 Transformer 的编码器-解码器（Encoder-Decoder）架构，同时，也出现了分别以这三种变体架构为主要结构的大型预训练语言模型，也就是 BERT^[23]系列，GPT 系列^[39-42]，以及后续的 T5^[27]模型。因此，本节将聚焦于 Transformer 的模型架构，以介绍这一模型的核心机制。

2.1.1 整体框架

Transformer 是由 Encoder-Decoder 框架组成的，由自注意力（Self-Attention）模块堆叠而成的 Seq2seq 结构，整体框架如图 2-1 所示。




图 2-1 Transformer 的整体架构

左边为编码器，由多个编码器块（Encoder Block）堆叠组成，右边为解码器，同样由多个解码器块（Decoder Block）构成。将用于中英语言翻译的 Transformer

想象为一个黑匣子，则其输入为英文句子，输出为翻译后的中文句子。在这个黑匣子里，编码器将输入的源序列转换为捕捉其本质的结构化格式，解码器接收编码数据并逐步生成输出。具体而言，先将输入的源序列进行嵌入，转换为编码器能够处理的数据形式；然后送入编码器，经过多个编码块后就可以得到源序列的编码信息矩阵；再将已生成的部分目标序列和编码器输出的编码信息矩阵传递到解码器中，解码器会根据当前翻译过的前 i 个单词和编码器生成的上下文表示生成第 $i+1$ 个单词的信息表示，然后将第 $i+1$ 个单词的信息表示送入全连接层和 Softmax^[43]层进行处理，得到各单词的输出概率，从而预测第 $i+1$ 个单词；然后再把获得的前 $i+1$ 个单词构成的目标序列作为解码器的输入，循环重复上一过程，直到模型预测出终止标记，表明序列的生成已经完成。这就是 Transformer 模型的大致流程，接下来将对编码器和解码器进行分析。

2.1.2 编码器

编码器是由多个编码器块组成，而每个编码器块是由多头自注意力层（Multi-Head Attention）、残差连接与归一化层（Add&Norm）和前馈神经网络（Feed Forward）组成的，如图 2-2 所示。其中，多头注意力层通过多个自注意力层将输入序列映射到不同的表示子空间中，生成多个含有不同上下文语义的表示矩阵，再将这些表示矩阵拼接，之后对拼接后的矩阵进行线性变换，融合不同的上下文信息。

（1）编码器的输入

将输入的文本序列送入编码器前，需要通过输入嵌入层获取输入句子中每一个单词的向量表示，如图 2-3 所示。该向量表示 $\mathbf{x}$ 由单词的词嵌入（Word Embedding）和位置嵌入（Positional Embedding, PE）相加得到。这是因为 Transformer 不采用 RNN 结构，不能利用单词间的序列信息，需要使用位置嵌入保存单词在序列中的相对或绝对位置。词嵌入可以通过很多方式获取，比如可以采用 Word2Vec^[44]、Glove^[45]等算法预训练得到，也可以在 Transformer 中训练得到。位置嵌入同样可以通过训练得到，也可以由公式计算得到。Transformer 则采用了后者，使用不同频率的正弦函数和余弦函数计算得到，详见式（2-1）和式（2-2）。

$$PE(pos, 2i) = \sin \frac{pos}{10000^{2i/d}} \quad (2-1)$$

$$PE(pos, 2i+1) = \cos \frac{pos}{10000^{2i+1/d}} \quad (2-2)$$

其中， pos 表示单词在句子中的位置， d 表示位置嵌入的维度，此维度与词嵌

入的维度一样， $2i$ 表示偶数的维度， $2i+1$ 表示奇数维度，即 $2i \leq d$ ， $2i+1 \leq d$ 。

将单词的词嵌入和位置嵌入相加，就可以得到单词的向量表示 $\mathbf{x}$ ，将所有单词的向量表示组合起来即可构成输入序列的矩阵表示 $\mathbf{X}$ 。然后将其输入编码器。




图 2-2 Transformer 的 Encoder 结构




图 2-3 编码器的输入嵌入层

(2) 多头自注意力层

多头自注意力层可以将任意单词间的关系直接建模，充分捕捉上下文语义，同时可以并行，优化了文本长距离依赖的处理，打破了循环神经结构的限制。多头自注意力层中的自注意力（Self-Attention）机制通过构建输入序列中的依赖关

系,被广泛应用于源语言编码和目标语言的生成。在给定输入序列的表示矩阵 $\mathbf{X}$ 后,使用线性变换矩阵 $\mathbf{W}^Q \in \mathbb{R}^{d \times d_q}$ 、 $\mathbf{W}^K \in \mathbb{R}^{d \times d_k}$ 和 $\mathbf{W}^V \in \mathbb{R}^{d \times d_v}$ 计算得到矩阵 $\mathbf{Q}$ 、 $\mathbf{K}$ 、 $\mathbf{V}$,即自注意力机制中的三元素:查询(Query)、键(Key)、值(Value),具体计算过程见式(2-3)、(2-4)以及(2-5)。

$$\mathbf{Q} = \mathbf{X}\mathbf{W}^Q \quad (2-3)$$

$$\mathbf{K} = \mathbf{X}\mathbf{W}^K \quad (2-4)$$

$$\mathbf{V} = \mathbf{X}\mathbf{W}^V \quad (2-5)$$

为了获得任意单词的上下文信息,将第 i 个单词的查询向量与其他位置单词的键向量做点积,得到单词间的注意力强度,如图2-4所示。其中1、2、3、4分别表示句子中位于第1个的单词、第2个的单词、第3个的单词和第4个的单词。




图 2-4 自注意力机制中的点积

为避免注意力强度过大引发梯度爆炸和收敛效率低下,在计算矩阵 $\mathbf{Q}$ 和矩阵 $\mathbf{K}$ 每一行向量的内积时,将其除以 $\sqrt{d_k}$ 进行稳定化处理。之后,使用 Softmax 函数对矩阵的每一行进行 Softmax 归一化,获得由每一个单词与其他单词的注意力系数构成的注意力向量,再将各注意力向量与相应位置的键向量相乘,得到最终的输出矩阵 $\mathbf{Z}$ 。矩阵 $\mathbf{Z}$ 充分捕捉了输入的上下文信息,减少了无关信息的影响。

上述计算过程可详见式(2-6):

$$\mathbf{Z} = \text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Softmax}\left(\frac{\mathbf{QK}^T}{\sqrt{d_k}}\right)\mathbf{V} \quad (2-6)$$

其中, d_k 为矩阵 $\mathbf{K}$ 的列数,自注意力操作的输出矩阵 $\mathbf{Z} \in \mathbb{R}^{l \times d_v}$, l 为输入的序列长度。

在多头注意力机制中,输入序列中的每一个单词的向量表示经过 h 组自注意力机制映射到不同的表示子空间中,以聚合更多上下文信息。在不同的子空间中均会按照公式(2-6)计算。得到含有不同上下文语义的输出矩阵组。之后,将矩阵组进行拼接(Concat)得到 $\mathbf{Z}_{concat}$,再按照式(2-7)进行线性变换,将不同子

空间中的上下文信息进行综合,得到多头自注意力层最终的输出 $\mathbf{Z}_{Multi-Head}^{\circ}$

$$\mathbf{Z}_{Multi-Head} = \mathbf{Z}_{concat} \mathbf{W}_0 \quad (2-7)$$

其中, $\mathbf{Z}_{Multi-Head} \in \mathbb{R}^{l \times d}$, $\mathbf{Z}_{concat} \in \mathbb{R}^{l \times (hd_v)}$, $\mathbf{W}_0 \in \mathbb{R}^{(hd_v) \times d}$ 。

(3) 残差连接与归一化层

与残差网络 (Residual Network, ResNet) [46] 类似, Transformer 架构的模型层级很深, 为避免因网络过深可能导致的梯度消失情况, 采用残差连接来保证模型梯度的平滑流动。如式 (2-8) 所示, 使用残差连接将当前层的输入信息添加到当前层的输出信息中, 作为下一层的输入。

$$\mathbf{x}^{L+1} = f(\mathbf{x}^L) + \mathbf{x}^L \quad (2-8)$$

其中, $\mathbf{x}^L$ 为第 L 层的输入, $f(\mathbf{x}^L)$ 表示经过当前层的映射函数得到的输出。

同时, 残差连接可以避免原始序列信息的丢失。多头注意力层忽略序列中元素的位置, 并且只能根据输入特征来学习它。删除残余连接意味着该信息在第一个多头注意力层之后即初始化之后丢失, 并且使用随机初始化的查询值和键值, 位置 i 的输出向量与其原始输入无关。注意力层的所有输出都可能表示相似或相同的信息, 并且模型没有机会区分哪些信息来自哪个输入元素。

为保证模型的稳定并加快训练速度, Transformer 中还添加了归一化层 [47], 如式 (2-9) 所示。

$$LayerNorm(\mathbf{x}) = \gamma \odot \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \varepsilon}} + \beta \quad (2-9)$$

其中, $\mathbf{x}$ 为输入向量, μ 和 σ 分别为输入数据的均值和标准差, γ 和 β 是可学习的缩放和偏移参数, 可以让模型能够适应不同的数据分布, $\odot$ 表示元素乘法, ε 是一个很小的正数, 默认值为 1×10^{-5} , 用于保证数值的稳定性, 防止分母为零。

(4) 前馈神经网络

前馈神经网络比较简单, 是由一个两层的全连接层构成, 第一层使用 ReLU 激活函数 [48], 第二层不使用激活函数, 对应的公式见式 (2-10)。

$$FFN(\mathbf{x}) = \max(0, \mathbf{x} \mathbf{W}_1 + \mathbf{b}_1) \mathbf{W}_2 + \mathbf{b}_2 \quad (2-10)$$

其中, $\mathbf{x}$ 是输入, $\mathbf{W}_1$ 、 $\mathbf{W}_2$ 、 $\mathbf{b}_1$ 和 $\mathbf{b}_2$ 是这两层全连接层对应的参数。

2.1.3 解码器

解码器负责处理来自编码器的编码输入表示 (Encoded Input Representations) 以及之前生成的单词 (previously generated tokens), 从而生成上下文感知的输出 (context-aware output)。解码器通过掩码多头自注意力 (Masked Multi-Head

Attention) 机制、残差连接与归一化层、多头交叉注意力 (Multi-Head Attention) 机制和前馈神经网络的协同工作, 生成上下文感知的表示, 最后再通过线性变换和 Softmax 层将其转换为输出概率, 用于预测下一个单词, 如图 2-5 所示。其中, 残差连接与归一化层、前馈神经网络层的结构均与编码器中的相同, 因此, 本小节聚焦于编码器与解码器之间的不同进行介绍。




图 2-5 Transformer 的 Decoder 结构

(1) 解码器的输入

在进行解码器处理前, 需要先将目标序列 (Target Sequence) 进行嵌入, 这里的目标序列指的是已经生成的部分序列, 即此前解码器输出的单词序列, 将这些单词被映射到嵌入向量空间中。嵌入过程仅发生在最底层的解码器块 (Bottom-most Decoder Block) 之前, 嵌入操作与编码器中的相同, 将目标序列

中各单词的词嵌入向量与位置嵌入向量相加，得到各单词的嵌入向量，再将这些嵌入向量作为行向量组成矩阵，作为解码器的输入，使后续的多头注意力机制能够处理。

(2) 多头掩码自注意力层

多头掩码自注意力层与多头自注意力层的构造相同，由多个掩码自注意力层组成。这里的掩码自注意力层也是通过计算序列中每个单词与其他单词之间的注意力分数（Scaled Scores），捕获序列中不同位置的关联性，只是为了防止解码器中某个位置的单词关注到未来的位置，在自注意力层的基础上增加了掩码机制。具体而言，在处理第*i*个单词时，只允许模型关注到当前及之前生成的单词，而不能关注到未来还未生成的单词。这是通过一个“向前看”的掩码（Look-Ahead Mask）实现的，如图 2-6 所示。图中的掩码矩阵为下三角矩阵，其中对角线以下为 0，表示允许关注当前及之前的位置，而对角线以上为极小值（ $-\infty$ ），表示屏蔽未来位置的注意力分数。将注意力分数矩阵与掩码矩阵相加，掩码部分的分数会变成极小值（ $-\infty$ ），并在经过 Softmax 函数时被置为 0，表示这些位置不会被考虑。处理后的分数矩阵称为“掩码后的分数”（Masked Scores），模型最终只会关注允许的前几个位置。




图 2-6 掩码计算

(3) 多头交叉注意力层

在序列生成任务中，如果解码器可以从编码器的输出中获取信息，那么就可以生成更符合源输入的目标输出。为了解决这一问题，Transformer 在解码器中引入了交叉注意力机制（Cross-Attention）。交叉注意力机制允许解码器在生成目标序列时，不仅关注自身的序列信息，还能够查看编码器的输出，即源序列的信息，解码器将编码器的输入与其处理对齐，确保每条信息完美同步。

交叉注意力机制与自注意力机制的计算方式相同，只是将编码器的输出作为键（Key）和值（Value），将解码器中上一层生成的表示作为查询（Query），使得解码器能够根据编码器生成的源序列表示，来决定如何生成目标序列。这样可以有效地对齐编码器的输入与解码器的输出，保证生成的目标序列能够参考源序列

中的信息。

2.2 通用大语言模型

通用大模型的发展历程经历了多个重要的阶段，随着技术的不断进步和计算资源的增强，模型的规模和能力也逐步扩展。最初，基于 Encoder-only 架构的模型主要聚焦于文本的理解和表示学习，比如 BERT 模型，能够有效地处理各种自然语言理解任务，如文本分类、问答和情感分析。然而，这类模型在生成任务上并不具备优势，因为它们缺乏生成能力，只能进行文本的编码和表示。之后，研究者开始尝试基于 Encoder-Decoder 架构建立模型，模型的能力得到了扩展。T5 和 BART 等模型采用了同时包含编码器和解码器的结构，能够处理从输入到输出的复杂转换，尤其在机器翻译和文本生成任务中表现出色。然而，随着基于 Decoder-Only 架构的 GPT-3 模型的发布，通用大模型的生成能力达到了新的高度。Decoder-Only 架构仅依赖于 Transformer 的解码器部分，采用自回归生成方式从左到右逐步预测文本的每个单词，具有极强的生成能力。该架构能够在极大的参数规模下，学习到更复杂的语言模型，并在多轮对话、长文本生成、创意内容创作等任务中展现出较强的流畅性和连贯性。此外，相比于 Encoder-Decoder 架构，Decoder-Only 模型的训练和推理过程更加简洁，且在生成任务中表现卓越。因此，Decoder-Only 架构成为了近年来自然语言生成领域的主流选择。本节将对当前主流的几种通用大模型进行详细介绍。

2.2.1 ChatGPT

ChatGPT 是 OpenAI 开发的基于 Transformer 架构的大型语言模型，属于 GPT（Generative Pre-trained Transformer）系列。该模型的核心技术基于自回归模型，通过对大量文本数据进行预训练，在此基础上利用微调和强化学习进一步提升其在对话生成和自然语言理解方面的能力。自 GPT-3 发布以来，OpenAI 不断扩展和优化其模型规模和性能，ChatGPT 逐渐成为了自然语言处理领域中的标杆之一。

ChatGPT 的训练方法主要包括预训练和微调两个阶段。在预训练阶段，模型通过大规模的文本数据进行自监督学习，学习语言模型的基本知识，包括语法、语义和上下文信息。在预训练之后，ChatGPT 通过微调进一步优化，针对特定任务进行定向训练。OpenAI 通过收集人工标注的对话数据集，调整模型在生成对话时的回答质量，使其更适合实际对话场景。为了进一步提升模型的对话质量，OpenAI 引入了强化学习与人类反馈（Reinforcement Learning with Human Feedback, RLHF）技术，通过人工评审对模型生成的对话进行评价，并使用强化学习算法

对模型进行更新，以提高其在对话生成中的准确度和自然度。

ChatGPT 凭借其强大的语言理解与生成能力，已经在多个领域得到了广泛应用，比如客户服务、教育培训、医疗保健、内容创作等^[49-53]。它能够生成高质量的文本，提供实时的对话回应。然而，尽管其在生成文本方面表现优异，ChatGPT 仍面临一些挑战，如生成内容的准确性、模型的可解释性以及潜在的伦理问题。随着技术的不断进步，ChatGPT 的能力有望得到进一步扩展和提升，特别是在多模态学习和个性化应用领域。

2.2.2 ChatGLM 系列

ChatGLM 系列模型是其中一类专注于中英双语对话的开源模型。ChatGLM-6B 是 ChatGLM 系列的第一代版本，基于 General Language Model (GLM) 架构^[54]，具有 62 亿参数。ChatGLM-6B 使用了和 ChatGPT 相似的技术，针对中文问答和对话进行了优化。经过约 1T 标识符的中英双语训练，并通过监督微调、反馈自助、人类反馈强化学习等技术的加持，ChatGLM-6B 已经能生成相当符合人类偏好的回答。

ChatGLM2-6B 作为 ChatGLM-6B 的升级版，不仅扩展了模型的上下文长度，还在模型结构上进行了优化，采用了更为高效的训练方法和算法，这使得 ChatGLM2-6B 能够在处理多轮对话、生成长篇文本以及进行知识问答等任务时，展现出更高的准确性和流畅性。

作为该系列第三代版本的 ChatGLM3-6B，相较于 ChatGLM2-6B 而言，其基础模型采用了更多样的训练数据、更充分的训练步数和更合理的训练策略，在语义、数学、推理、代码、知识等不同角度的数据集上展现了更卓越的性能。ChatGLM3-6B 采用了全新设计的 Prompt 格式，除了正常的多轮对话外，同时还支持工具调用 (Function Call)、代码执行 (Code Interpreter)、智能体 (Agent) 任务^[55]等复杂场景。

ChatGLM 系列模型作为自然语言处理领域的重要成果之一，以其强大的对话生成能力和高度的上下文感知性为智能对话系统的发展注入了新的活力，未来，ChatGLM 系列模型将在更多场景下发挥重要作用，为人们的生活和工作带来更多便利和智能化体验。

2.2.3 DeepSeek

DeepSeek 是由中国人工智能公司深度求索开发的大型语言模型，在自然语言处理、代码生成、数学推理等领域展现出卓越的性能^[56]。该模型基于 Transformer

架构,并采用混合专家(Mixture of Experts, MoE)^[57]技术提升训练和推理效率^[58],例如 DeepSeek-MoE 模型^[59]通过约 160 亿激活参数实现了与千亿参数模型相当的性能,显著降低了计算成本。

DeepSeek 模型在多个权威基准测试中表现优异,尤其在数学和编程任务上达到或接近 GPT-4 水平,例如,DeepSeek-R1 版本的数学解题能力已突破 90%的准确率^[60]。该系列模型不仅支持通用领域任务,还通过领域微调服务于金融、医疗等垂直场景。深度求索坚持开源策略,公开了多个模型的参数和训练细节,如 DeepSeek-7B 和 DeepSeek-MoE-16B,推动学术与工业界的协作创新。研发者以“探索未知,拓展人类认知边界”为使命,持续优化模型的高效性、可控性和安全性,其技术已应用于智能搜索、内容生成、教育辅助等场景^[61-63],并积极探索多模态与具身智能的前沿方向。

2.2.4 参数高效微调技术

为将在通用语料库上预训练得到的通用大语言模型应用于下游任务上,通常会使用下游任务相关数据对通用大语言模型进行微调,使其在下游任务上表现出较好的性能。由于大语言模型的参数规模越来越大,需要对大语言模型的每一个参数都进行更新的全量微调对于普通用户来说很难实现。因此,研究者们提出了各种各样的参数高效微调(Parameter-Efficient Fine-Tuning, PEFT)技术,即固定住模型的大部分参数,仅调整模型的一小部分参数来达到与全量微调接近的效果,这部分被调整的参数既可以是模型自有的参数,也可以是额外加入的一些参数。

Lialin 等人将现有的参数高效微调技术分为三大类:基于添加额外参数(Addition-based)的参数高效微调技术;选取一部分参数更新(Selective-based)的参数高效微调技术;基于重参数化(Reparametrization-based)的参数高效微调技术^[64]。Addition-based 方法的主要思想是用额外的参数或层增加现有的预训练模型,并只训练新添加的参数。在这个类别中,又出现了两个大的子类别:类适配器(Adapter-like)方法和软提示(Soft prompts)。比如给模型增加一个额外知识模块,让其去适配下游任务的适配器微调(Adapter Tuning)^[65];在输入数据或输出结果上增加前缀标记(prefix token)作提示的前缀微调(Prefix Tuning),在微调时,将模型的其他部分冻住,单独训练前缀标记相关的参数,每个下游任务都可以单独训练一份专用的前缀标记^[66]。与 Addition-based 方法不同,Selective-based 方法在微调期间只训练模型参数的一个子集,这意味着只有一部分参数会被更新,而其余参数保持不变,比如只更新模型偏置项的 BitFit 微调技术^[67]。Reparametrization-based 方法需要在训练期间构建原始模型参数的低维重参数化,然后在推理时将这些参数等价地转换回原始形式,比如用低维矩阵近似分

解高维参数矩阵的低秩适配器(Low-Rank Adaptation, LoRA)微调^[68],如式(2-11)所示。

$$\mathbf{y} = \mathbf{W}\mathbf{x} + \mathbf{B}\mathbf{A}\mathbf{x} \quad (2-11)$$

其中, $\mathbf{x}$ 为输入向量, $\mathbf{y}$ 为输出值, $\mathbf{W} \in \mathbb{R}^{d \times d}$, 表示冻结的预训练权重, 通过低秩矩阵 $\mathbf{A} \in \mathbb{R}^{r \times d}$ 和低秩矩阵 $\mathbf{B} \in \mathbb{R}^{d \times r}$ 构建低秩适配器来近似分解微调过程中产生的权重增量矩阵, 且 $r \ll d$, 大大降低了需要更新的参数量。

在众多微调方法中, LoRA 微调是一种高效且性能卓越的选择。它通过引入低秩矩阵来调整预训练模型, 仅需微调少量参数, 就能够实现与全量微调接近的性能, 甚至在某些任务上表现更好。与 Adapter Tuning、Prefix Tuning 和 BitFit 相比, LoRA 微调能够在保持高效性的同时, 提供更大的灵活性和更强的任务适应性。而且 LoRA 微调的内存和计算需求相对较低, 尤其适合在资源有限的情况下使用。

2.3 RAG 技术

检索增强生成(Retrieval Augmented Generation, RAG)技术将检索机制与生成模型有机结合, 通过先检索后生成的策略提升模型性能^[69]。如图 2-7 所示, 该技术的工作流程主要分为两个阶段: 首先, 系统从外部知识库中检索与问题相关的信息; 之后, 通过提示(Prompt)模板将这些检索到的信息作为上下文输入生成模型, 从而产生更准确的回答。其中, 相似度检索是指计算查询向量与数据库中存储向量的相似性得分, 返回得分高的记录, 常见的相似性计算方法包括: 余弦相似性、欧氏距离、曼哈顿距离等。

Prompt 作为生成模型的直接输入, 是影响模型输出准确率的关键因素之一。在构建 RAG 中的 Prompt 时, 通常有以下几个关键规则需要遵循: 首先, Prompt 应当明确指定任务的目标, 例如, 可以指示生成模型“基于以下检索结果生成详细的回答”。其次, Prompt 的设计应当保持简洁, 但要提供足够的上下文信息, 使生成模型能够准确理解并回答问题。此外, 还可以在 Prompt 中明确规定输出的格式, 确保生成模型生成符合预期的结构化答案。最后, 为了提高生成质量, Prompt 中可以包括一些引导性提示, 减少模型因缺少相关知识而胡说八道的情况, 帮助模型更好地生成回答。通过合理设计 Prompt, RAG 技术可以有效地提升生成的文本质量, 避免因知识库信息不足或模型理解不准确导致的错误回答。

将 RAG 技术引入大语言模型的上下文学习中, 不仅能有效缓解模型的幻觉问题, 还能及时更新知识库, 具有实现简单、效果显著的特点。尽管微调方法在知识密集型任务中也有一定效果, 但 RAG 在应对已知知识和新知识方面都展现

出更优的性能。值得注意的是，RAG 技术的应用已从最初的文本生成扩展到多模态领域。在音频处理方面，Huang 等人提出的 Make-An-Audio 模型就是一个典型示例，该模型采用提示增强的扩散模型架构，成功解决了音频领域面临的两大挑战：一是高质量文本-音频配对数据的稀缺性；二是对长时连续音频的建模难题^[70]。此外，RAG 技术在图像和视频处理领域也取得了显著进展，展现出强大的跨模态适应能力。




图 2-7 RAG 技术的工作流程示意图

2.4 智能体

智能体（Agent）这一概念源自哲学领域，在人工智能语境下，它特指具有智能行为特征并展现出自主性、反应性、主动性以及交互能力的实体^[71]。这种技术范式在医疗健康领域展现出显著的应用价值：通过协助医生提升工作效率与诊断准确性，优化患者就医体验与健康管理效果，特别是在提供远程医疗、个性化治疗建议和临床决策支持等在线服务方面，为解决医疗资源分布不均问题提供了创新性解决方案。

智能体的技术特性使其成为系统集成的理想架构选择。其核心优势体现在三个方面：首先是自主决策能力，能够在无持续人工干预的情况下独立完成指定任务，并根据环境变化和自身状态动态调整行为策略，从而显著提升系统的适应性和容错能力；其次是实时响应机制，能够灵敏感知环境变化并做出及时反馈，这

种快速响应特性使系统能够有效应对复杂多变的实际场景，确保运行的可靠性与稳定性；最后是模块化设计理念，通过标准化的组件封装，实现系统功能的灵活组合与高效复用，这种设计显著降低了系统间的耦合度，大幅提升了系统的可维护性和扩展性。

2.5 本章小结

本章首先详细介绍了 Transformer 架构的核心组成部分，包括其编码器和解码器的结构及其在自然语言处理中的重要作用。随后，对当前主流的通用大语言模型进行了概述，重点探讨了 GPT 系列、ChatGLM 系列以及近期备受关注的 DeepSeek 模型的特点与应用场景。在此基础上，介绍了参数高效微调技术，为大语言模型在特定任务上的优化提供了理论支持。然后阐述了 RAG 技术通过结合外部知识库提升模型生成能力的方法与优势。此外，对智能体的概念及其在复杂任务中的应用进行了探讨，展示了其在模拟人类决策和交互中的潜力。本章通过对 Transformer 架构、通用大模型、参数高效微调技术、RAG 技术以及智能体的全面介绍，为后续章节的研究与应用奠定了理论基础，并为相关领域的实践提供了技术指导。

第三章 基于中文医疗对话数据微调的轻问诊模型

大型语言模型在一般领域的各种自然语言处理任务中取得了显著的成功。然而，由于领域知识有限，大型语言模型有时会在医学事实上出现幻觉现象。这些缺点对大型语言模型在医疗环境中的使用构成潜在风险。为了应对这一挑战，本章提出了基于中文医疗对话数据微调的轻问诊模型 Med-Chat，该模型通过使用医疗对话数据集 DISC-Med-SFT 对通用大型语言模型 ChatGLM3-6B 进行微调，并构建医学知识库为其提供准确的知识来源。最后，针对大型语言模型生成的回答进行级联去重，使其生成精确、可靠的回答。

3.1 引言

以 ChatGPT 为代表的大型语言模型展示了大规模预训练语言模型在理解指令和生成自然语言文本方面的卓越性能。与较小的模型相比，大型语言模型在各种自然语言处理任务中表现出很强的泛化性能和解决复杂任务的独特涌现能力，推动了自然语言处理领域的发展。虽然 ChatGPT 处于非开源状态，但是开源社区有着许多替代方案，比如 Bloom^[72]、Llama、ChatGLM 等，这些通用大型语言模型为在各种下游领域应用大型语言模型提供了坚实的基础。

然而，在这些进步的同时，大型语言模型也表现出幻觉问题。由于缺少或遗忘相关知识，大型语言模型在不确定或未见过的的问题上有时会胡编乱造，给出错误的回答，进而导致其生成的答案与现实世界的事实不一致^[73]。

如图 3-1 所示，当向大型语言模型 ChatGLM3-6B 询问它不确定或未见过的的问题时，图片中的红色文本部分展示了大型语言模型生成的错误回答。大型语言模型将“军刀综合征”解释为一种战争创伤病症，并描述了虚构的症状和治疗方法，诸如“指在军事冲突中或军事训练中发生的身体损伤”以及其发病原因等。此回答完全偏离了实际的医学定义，说明大型语言模型在不确定或未见过的的问题上可能产生幻想性输出。这种错误信息的生成，即幻觉现象，是当前大语言模型的一大局限性，特别是在处理专业或复杂领域的问题时。

针对医疗大模型的广泛应用前景，以及大型语言模型存在的幻觉问题，本文提出了基于中文医疗对话数据微调的轻问诊模型 Med-Chat。Med-Chat 的具体情况如图 3-2 所示。

首先，利用中文医学数据集 DISC-Med-SFT 对通用大型语言模型 ChatGLM3-6B 进行微调，使其具备医学问答的基本能力。之后，为了缓解大型语言模型的幻觉问题，将知识库接入大型语言模型，在生成回答时，先在知识库中

查找输入问题涉及的相关知识，将查找到的知识作为提示，与问题一起送入大型语言模型，生成回答。同时，在最终回答生成前添加级联去重模块，将大型语言模型生成的初次回答中的重复字词进行筛选、过滤，得到标准、精确的最终回答。




图 3-1 大语言模型的幻觉示例




图 3-2 构建 Med-Chat 的方法总览

3. 2 LoRA 微调

为了让大语言模型适应医疗垂直领域，使用仅更新小部分参数就可以近似达到全量微调效果的参数高效微调技术对大型模型进行高效且成本较低的微调操作，增强其在医疗问答上的能力。Adapter Tuning 添加了适配器，不仅需要耗费额外的运算量在适配器上，在并行训练时，它还会产生额外的通讯量，增加通讯时间。

而 Prefix Tuning 不仅较难训练，而且模型的效果并不严格随着前缀标记数量的增加而上升。同时，由于有限的资源，输入数据的长度一般是固定的，在输入数据中增加了前缀标记，原始数据的存储空间受到挤压，减少了输入层的有效信息长度，这可能会影响原始数据中提示的表达能力。而基于重参数化的 LoRA 微调利用低秩结构很好地避免了这些不足。

全参数微调是指对模型的每一个参数都进行更新，那么微调后的参数就可以表示为冻住的预训练权重 W 与微调过程中产生的权重增量 ΔW 之和，如图 3-3 中的 (a) 所示。LoRA 则是用低维矩阵 A 和 B 来近似 ΔW ，如图 3-3 中的 (b) 所示。在模型的结构网络中增加一个由低维矩阵 A 和 B 相乘构成的旁路结构。矩阵 A 的维度是 $r \times d$ ，矩阵 B 的维度是 $d \times r$ ，其中 $r \ll d$ 。这样，需要微调的参数量从 $d \times d$ 降为 $2 \times r \times d$ ，远小于全参数微调需要更新的参数量 $d \times d$ 。既降低了需要微调的参数量，也没有加深模型的深度，同时不改变输入和输出数据的维度。

设输入为 x ，输出为 y ，则有：

$$y = Wx + \Delta Wx$$

(3-1)




图 3-3 全参数微调 and LoRA 微调示意图

其中, $\mathbf{W} \in \mathbb{R}^{d \times d}$, 表示预训练权重, $\Delta \mathbf{W} \in \mathbb{R}^{d \times d}$, 表示微调产生的权重增量。

然后, 使用低秩矩阵 $\mathbf{A}$ 和低秩矩阵 $\mathbf{B}$ 来近似分解矩阵 $\Delta \mathbf{W}$, 即:

$$\Delta \mathbf{W} = \mathbf{B}\mathbf{A} \quad (3-2)$$

其中, $\mathbf{A} \in \mathbb{R}^{r \times d}$, $\mathbf{B} \in \mathbb{R}^{d \times r}$, $r \ll d$ 。

那么, 在 LoRA 微调下, 则有

$$\mathbf{y} = \mathbf{W}\mathbf{x} + \mathbf{B}\mathbf{A}\mathbf{x} \quad (3-3)$$

LoRA 训练时, 冻结预训练权重 $\mathbf{W}$, 只训练旁路参数 $\mathbf{A}$ 和 $\mathbf{B}$ 。推理时, 按照公式 (3-3) 合并预训练权重和权重增量, 之后正常做前向传播, 生成输出结果。由于 $\mathbf{A}$ 和 $\mathbf{B}$ 的参数数量远远小于 $\mathbf{W}$, 那么训练时需要的显存开销就大大降低; 并且因为没有改变模型架构, 也不会产生推理上的延迟。这种方法在不牺牲推理速度的前提下, 大大减少了需要更新的参数量, 以较低的微调成本提升了模型在垂直领域上的性能。

3.3 外接向量知识库

虽然微调可以使模型学习到下游任务所涉及领域的专业知识, 但通过微调注入的医学知识有限, 模型在生成回答时会产生幻觉现象, 即胡编乱造、生成不符合事实的错误回答。主要体现在以下两个方面: 一是知识不足, 当模型回答涉及到未学过知识的问题时, 它会编造相关知识作为回答依据, 给出错误的答案, 造成幻觉现象。二是数据召回失败, 模型在回答部分问题时会无法准确回忆起相关知识, 因虚假的相关性产生幻觉, 出现回答错误或不准确的情况。

针对这两种情况, 本文使用医学知识构建医学知识库, 作为模型的外接组件为模型提供医学知识。这样既不需要继续预训练或微调为模型注入新的知识, 降低了更新知识的成本, 也能提供准确的知识, 使模型的回答更具有信服力; 同时, 将从训练集中提取到的医学知识作为知识库的知识来源之一, 可以减少训练数据召回失败的比例, 进而缓解幻觉问题。

3.3.1 构建向量知识库

由于向量数据库中的数据以向量作为基本单位, 对向量进行存储、处理及检索。当处理大量甚至海量的数据时, 向量数据库的索引和查询算法的效率明显高于传统数据库, 因此本文选择构建向量数据库作为知识库。通过提取训练对话集中涉及的疾病名称和药物等医学实体, 收集相关的医学文本资料以及近百篇临床指南。然后对这些文本资料进行数据清洗, 去除其中的噪音信息, 保证疾病、症

状、药物和诊疗手段等重要信息的清晰度，获得最终的资料文档。之后将资料文档中包含的医学知识通过嵌入（Embedding）转化为高维向量，最终构建向量知识库，具体过程如图 3-4 所示。




图 3-4 向量知识库的构建

首先，加载包含大量医学知识的本地文档，读取其中的文本信息。然后对信息进行预处理，将其分割成多个文本块，使其更便于后续的处理。之后使用 Embedding 模型将每个文本块转化为可以捕捉其语义信息知识向量。最后将生成的知识向量存储在同一个知识向量库中，用于后续的相似性检索。具体实现的主要代码如图 3-5 所示，其中，file_path 表示本地存储的知识文档。

```
#加载文档
file_path = "./vb_n.pdf"
loaders = []
loaders.append(PyPDFLoader(file_path))
#读取文档
texts = []
for loader in loaders:
    texts.extend(loader.load())
#切分文档
text_splitter = RecursiveCharacterTextSplitter(chunk_size=500, chunk_overlap=50)
split_doc = text_splitter.split_documents(texts)
split_docs_chunked = split_list(split_doc, 41000)

# 嵌入
embeddings = HuggingFaceEmbeddings(model_name=embedding_model_dict[EMBEDDING_MODEL])
embeddings.client = sentence_transformers.SentenceTransformer(embeddings.model_name,device=DEVICE)

#构建向量知识库
for split_docs_chunk in split_docs_chunked:
    vectordb = Chroma.from_documents(documents=split_docs_chunk,
                                     embedding=embeddings,
                                     persist_directory=persist_directory)

    vectordb.persist()
```

图 3-5 构建向量知识库的部分代码块

3.3.2 RAG 技术接入

向量知识库构建完成后，再使用检索增强生成技术将知识库接入模型。首先

应用 Embedding 模型，将输入的问题转化为向量表示，在搭建好的知识库中匹配出与问题向量最相似的前 k 个知识向量，这些知识向量表示与问题最相关的医学知识。将获得的知识和问题结合，然后输入给模型，让其生成精准的回答。具体详细流程如图 3-6 所示，相关代码块如图 3-7 所示。




图 3-6 外接知识库

```
# 嵌入模型
embeddings = HuggingFaceEmbeddings(model_name=embedding_model_dict[EMBEDDING_MODEL])
embeddings.client = sentence_transformers.SentenceTransformer(embeddings.model_name, device=DEVICE)

# 加载向量知识库
vectordb = Chroma(persist_directory=filepath, embedding_function=embeddings)

# 加载微调后的模型
chatglm = ChatGLM3(model_path=model_dir)
chatglm.load_model()
llm = chatglm

# Prompt提示词
template = """使用以下上下文来回答最后的问题。如果你不知道答案，就说你不知道，不要试图编造答案。
            {context}
            问题: {question}
            """

QA_CHAIN_PROMPT = PromptTemplate(input_variables=["context", "question"], template=template)

# 在向量知识库中检索相关知识，并生成回答
qa_chain = RetrievalQA.from_chain_type(
    llm,
    retriever=vectordb.as_retriever(search_kwargs={"k": 1}),
    return_source_documents=True,
    chain_type_kwargs={"prompt": QA_CHAIN_PROMPT}
)
```

图 3-7 外接知识库的部分代码块

在推理时，先将输入的问题通过 Embedding 模型转化为问题向量，以便与知识库中的知识向量进行比较。之后计算输入的问题向量与知识库中各个知识向量之间的余弦相似性，将其中相似度最高的前 k 个知识向量提取出来，转化为相应的知识块，通过 Prompt 模板生成含有丰富背景知识的 Prompt，与输入的问题一起

作为输入数据送入模型，生成包含准确医学知识的回答。图 3-6 展示了如何通过外部知识库的支持，增强模型的问答能力。关键步骤包括向量化、相似性检索以及 Prompt 生成这三步。这种方法有效地将专业知识与模型的生成能力结合，减少了数据召回失败的次数，提高了模型在医学领域的准确性，缓解了幻觉现象。

3.4 级联去重

级联去重模块是一种用于处理重复输出的技术，尤其在医疗大模型中应用时，可以有效减少生成内容中的冗余重复信息。医疗大模型在回答问题或生成长文本时，可能会因为模型结构或生成机制导致内容重复，为了解决这个问题，本文提出了级联去重模块。具体示例如图 3-8 所示，级联去重模块可以去除词组间和字符间的重复，从而使模型生成的回答变得流畅、准确。



图 3-8 级联去重的具体示例

首先，去除词组级重复：

$$Clean(S) = Joinsep(Unique(W)) \tag{3-4}$$

其中， S 表示输入的句子， $W = Split_{sep}(S)$ ，表示将句子 S 按指定的分隔符 sep 分割为一个词列表 W ，分隔符 sep 表示通用的分隔符，可以是任意字符，比如逗号(,)、空格()、分号(;)等。 $Unique(W)$ 表示依次遍历词列表 W ，去除重复词，并返回按首次出现顺序排列的唯一词列表 W' 。 $Joinsep(W')$ 表示将去重后的词列表 W' 按分隔符 sep 重新连接成一个新的句子 T ，即 $T = Clean(S)$ 。

然后，去除字符级重复：

令 $T = \{t_1, t_2, \dots, t_n\}$, t_i 表示字符串中的第 i 个字, n 是字符串的长度, 则有:

$$T' = \text{Concat}(t'_i) \tag{3-5}$$

其中,

$$t'_i = \begin{cases} t_i, t_i \neq t_{i-1} \\ \varnothing, otherwise \end{cases}, i = 1, \dots, n \tag{3-6}$$

在当前字符和其前一个字符不同时, 将当前字符与其前一个字符进行拼接; 否则, 直接跳过当前字符, 继续比较下一个字符, 直至遍历完所有字符, 得到最终结果 T' 。

在医疗大模型的生成过程中, 可能会输出相同的词或句子多次, 级联去重模块通过消除冗余内容, 提升回答的简洁性与准确性, 提高了信息传递的效率。同时, 由于 $Unique(W)$ 依次遍历, 保证了词组的位置顺序不变, 避免打乱原有的上下文结构, 使处理后的输出仍然连贯合理。

3.5 实验

3.5.1 数据集介绍

实验采用中文医学对话数据集 DISC-Med-SFT, 该数据集采用了目标导向的策略, 通过对现有医疗数据集进行重新构建而得到的^[74]。该数据集包含约 47 万条医学对话数据, 如表 3.1 所示, 它以真实咨询对话记录 MedDialog^[75]、cMedQA2^[76]以及医学知识图谱 CMeKG^[13]作为信息源, 使用大型语言模型重构对话, 生成质量更高的对话样本。

表 3.1 DISC-Med-SFT 数据集构成

数据来源	样本量
MedDialog	400K
cMedQA2	20K
CMeKG	50K

该数据集由单轮对话和多轮对话构成, 这两种对话数据分别以“用户: xxx\n 医生: xxx\n”和“用户: xxx\n 医生: xxx\n 用户: xxx\n 医生: ……”的形式统一为一种指令格式, 如表 3.2 所示和表 3.3 所示。

表 3.2 单轮医疗对话问答示例

单轮对话
用户: 脉管炎咨询, 脉管炎咨询

续表 3.2 单轮医疗对话问答示例

单轮对话
医生：您好，我了解到您对脉管炎有一些疑问。脉管炎是指血管壁的炎症，可能导致血管狭窄或堵塞，进而影响血液供应。为了更好地了解您的情况，我建议您进行下肢动脉 MRA 或 CTA 检查，这是一种造影检查，可以帮助我们了解为什么会出现左脚发黑的情况。根据检查结果，我们可以确定下一步的治疗方案。此外，您可以尝试服用扩张毛细血管的药物，这有助于改善血液循环。请注意，药物的使用前最好咨询医生的建议。请问还有其他问题吗？我会尽力帮助您解答。

表 3.3 多轮医疗对话问答示例

多轮对话
用户：红色凸起疤痕疙瘩，我估计自己可能是疤痕体质，两个手臂上的红色疤痕疙瘩都是大约五年前的小伤口演变而来的，当时也没在意，现在觉得很难看，希望至少能平复下去，颜色变浅。
医生：非常抱歉听到您的困扰。根据您的描述，这些红色凸起的疤痕疙瘩可能是疤痕增生。对于疤痕增生，我们通常会采用局部注射激素治疗。不过，需要注意的是，这种治疗方法容易导致复发。另外，手术和激光等治疗方法，正如您所提到的，对于疤痕体质的人来说，效果可能不佳甚至可能加重疤痕的情况。如果您确实考虑手术治疗，术后需要立即进行放射治疗以配合恢复。然而，需要提醒的是，放射治疗可能存在引发皮肤癌的风险，因此愿意接受这种治疗的人并不多。
用户：谢谢医生的解答，我了解了。那除了手术和激光治疗，还有其它方法可以尝试吗？
医生：除了手术和激光治疗，您还可以尝试其他一些方法来改善疤痕的情况。首先，保持伤口干燥和清洁，避免摩擦和刺激，有助于减少疤痕的形成。其次，您可以尝试使用一些疤痕修复产品，如硅胶贴或疤痕修复霜，这些产品可以帮助减轻疤痕的颜色和凸起程度。此外，保持良好的营养和充足的睡眠也对皮肤的修复有帮助。如果您有其他疑问或需要进一步的建议，请随时告诉我。
用户：谢谢医生的建议，我会尝试您提到的方法来改善疤痕的情况。
医生：不客气，希望我的建议对您有所帮助。如果您在尝试这些方法后仍然有困扰，建议您及时就医，向专业医生寻求进一步的帮助和建议。祝您早日康复！如果您还有其他问题，我随时为您解答。

3.5.2 实验设置

医疗大模型实验环境包括 Intel Xeon Gold 522 CPU、NVIDIA Tesla V100 GPU、Ubuntu 20.04 操作系统，以及 CUDA 11.8 和 cuDNN 8.9.7 加速库，用于高效处理

大规模数据。下面表 3.4 是对环境各方面的详细介绍。

表 3.4 实验环境介绍

配置	参数
CPU	Intel Xeon Gold 522
GPU	NVIDIA Tesla V100
操作系统	Ubuntu 20.04
加速环境	CUDA11.8 CUDNN 8.9.7

使用包含 470K 条问答数据对的 DISC-Med-SFT 数据集对大模型 ChatGLM3-6B 进行微调。按照 9:1 的比例对数据集 DISC-Med-SFT 进行划分，随机抽取 90%的对话数据作为训练集，其余的 10%作为测试集。其中，batch size 设为 4,使用 AdamW 优化器，学习率设为 5×10^{-5} ，共进行 200,000 次迭代步骤，具体超参数设置如表 3.5 所示。

表 3.5 实验超参数设置表

超参数	相应值
批次大小（batch-size）	4
迭代次数（iteration）	200000
学习率	5×10^{-5}
LoRA 的秩 r	8

观察训练过程中损失函数值的变化，损失函数值随着迭代次数的增加而减少，直到损失值的波动达到稳定。在训练过程中，设置每 10 次迭代步骤后打印相应日志，记录模型微调时的损失值变化。如图 3-9 所示，模型在训练初期时损失值快速下降。




图 3-9 前 2, 000 次迭代的损失函数值曲线图

由于每次迭代步骤只送入 4 条输入数据，因此前 100,000 次迭代的输入几乎全都不同。模型通过不断调整内部参数，学习训练数据中的复杂语义，损失函数值不停地上下波动，如图 3-10 所示。随着迭代次数的增加，开始有重复的输入数据送入模型，训练损失值波动的中间值逐渐降低，然后维稳在一个上下小幅波动的状态，如图 3-11 所示。




图 3-10 前 100,000 次迭代的损失函数值曲线图




图 3-11 整个训练过程的损失函数值曲线图

3.5.3 评价指标

BLEU^[77]是最早用于机器翻译评估的指标之一，用来衡量生成文本和参考文本的相似度。BLEU 主要注重精确率（Precision），即生成文本中与参考文本匹配的 n 元词组（ n -gram）的比例。

BLEU 的工作原理：

$$BLEU = BP * \exp\left(\frac{1}{N} \sum_{n=1}^N \log P_n\right) \quad (3-7)$$

其中, P_n 为精确率, 表示生成文本中与参考文本匹配的 n -gram 所占的比例, 即:

$$P_n = \frac{\sum_{S \in \text{ReferenceSummaries}} \sum_{\text{gram}_n} \text{Count}_{\text{match}}(\text{gram}_n)}{\sum_{S \in \text{generateSummaries}} \sum_{\text{gram}_n} \text{Count}(\text{gram}_n)} \quad (3-8)$$

BP 是惩罚因子, 用来确保模型不会为了精确率而生成简短不完整的文本。

$$BP = \begin{cases} 1, & c > r \\ \exp\left(1 - \frac{r}{c}\right), & c \leq r \end{cases} \quad (3-9)$$

其中, c 表示生成文本的长度, r 表示参考文本的长度, 如果生成的文本过短, 尽管有高的精确率, 也会降低 BLEU 分数。因此使用 BLEU 作为评估指标, 即能考虑到生成答案的精确度, 又能考虑到生成答案的流畅度。

与 BLEU 更注重精确率不同, ROUGE-N 通过统计 n -gram 上的召回率, 即参考文本中与生成文本重叠的 n -gram 所占的比例, 衡量生成的文本与参考文本之间的相似度^[78], 其计算公式见式 (3-10)。其中, N 可以是任意整数, 代表不同长度的 n -gram, 分母为在参考文本中 n -gram 的个数, 分子为参考文本与生成文本共有的 n -gram 的个数。

$$ROUGE - N = \frac{\sum_{S \in \text{ReferenceSummaries}} \sum_{\text{gram}_n \in S} \text{Count}_{\text{match}}(\text{gram}_n)}{\sum_{S \in \text{ReferenceSummaries}} \sum_{\text{gram}_n \in S} \text{Count}(\text{gram}_n)} \quad (3-10)$$

F1 分数是精确率和召回率的调和平均数, 可以更全面地考虑生成文本的质量。令 F1-N 表示不同长度的 n -gram 对应的 F1 分数:

$$F1 - N = \frac{2P_n R_n}{P_n + R_n} \quad (3-11)$$

其中, P_n 为精确率, 表示生成文本中的 n -gram 与参考文本匹配的比例, 具体原理见公式 (3-8)。 R_n 为召回率, 表示参考文本中的 n -gram 与生成文本匹配的比例, 其具体计算公式与式 (3-10) 相同。

3.5.4 实验结果

将轻问诊模型 Med-Chat 和一些优秀的大语言模型 Baichuan, Ben Tsao, ChatGLM3-6B 进行对比, 对比实验的结果如表 3.6 所示。Baichuan 是一个开源的

中文大语言模型，致力于自然语言处理任务，专注于文本生成、理解和推理等功能，适用于多种场景^[7]。Ben Tsao 是一个中文医学大语言模型，它基于 LLaMA-7B 基座模型，使用问答数据和多轮对话数据进行有监督的微调。ChatGLM3-6B 是一个具有 60 亿参数的对话语言模型，旨在支持多轮对话和复杂任务的文本生成，具有较强的理解和应答能力。Med-Chat 是在 ChatGLM3-6B 的基础上经微调、外接知识库并去重后，最终得到的医疗大模型。图 3-12 比较了不同大语言模型在 BLEU 指标和 F1 分数上的表现，表 3.6 额外展示了各个模型在不同 n-gram 上的准确率。




图 3-12 大语言模型在评估指标上的表现

表 3.6 评估结果

	BLEU	P ₁	P ₂	P ₃	P ₄	F1-1	F1-2	ROUGE-2
Baichuan	6.57	43.71	13.66	5.13	2.25	35.68	11.02	11.31
Ben Tsao	1.65	28.99	6.97	2.79	1.34	19.18	5.29	4.40
ChatGLM3-6B	7.36	39.06	11.58	4.14	1.71	36.73	10.63	12.08
Med-Chat	8.82	50.10	19.20	9.17	5.03	39.77	15.42	13.86

由图 3-12 可以发现，Med-Chat 在所有指标上都取得了最佳表现，分别为 BLEU 的 8.82、F1-1 的 39.77 和 F1-2 的 15.42。Med-Chat 和 ChatGLM3-6B 在 BLEU 指标上的值分别为 8.82 和 7.36，提升了 1.46。较高的 BLEU 值代表了 Med-Chat 生成的文本在词语和短语的选择上与参考文本相似度较高，说明模型可以生成内容、语义和表达方式都接近真实或理想的参考答案。同样，Med-Chat 在 F1-1、F1-2 指标上比 ChatGLM3-6B 分别高了 3.04 和 4.79。这表明 Med-Chat 模型在平衡准确性和覆盖度上表现出色，生成内容不仅用词精准，还全面且符合参考文本的预期

结构。与 ChatGLM3-6B 相比, Med-Chat 在 P_1 , P_2 , P_3 , P_4 指标上取得的提升分别为 11.04, 7.62, 5.03, 3.32, 这表明了 Med-Chat 生成的文本在逐步增加短语长度时保持一致性和精确度。与此同时, Med-Chat 在各方面的指标均优于开源的中文大语言模型 Baichuan 和中文医学大语言模型 Ben Tsao。

与基模型 ChatGLM3-6B 相比, 利用专门的医疗数据和医学知识训练优化后的 Med-Chat, 减少了大型语言模型在医学术语、诊断描述上的误解, 以及生成误导性或不专业建议的情况, 具体示例如表 3.7 所示。

表 3.7 Med-Chat 与 ChatGLM3 生成的回答

Q: 面瘫后遗症会引起痉挛和大面部肌肉运动吗?
ChatGLM3-6B: 面瘫后遗症不会引起痉挛和大面部肌肉运动。面瘫是一种神经功能障碍, 通常由于面神经的损伤或炎症引起。面瘫后遗症可能包括面部表情肌僵硬、对称性缺失的面部表情困难等。但是面瘫后遗症一般不会引起痉挛和大面部肌肉运动。
Med-Chat: 面瘫后遗症可能会引起痉挛和大面部肌肉运动。但面瘫后遗症可能会引起面部的运动困难。面瘫后遗症的症状会因个体差异而有所不同, 有些患者可能会出现面部肌肉运动困难, 而有些患者可能没有明显的症状。如果您有面瘫后遗症的症状, 建议您尽快就医, 以便进行专业的评估和治疗。

表 3.7 展示了 Med-Chat 和 ChatGLM3-6B 对同一问题“面瘫后遗症会引起痉挛和大面部肌肉运动吗?”的不同回答。Med-Chat 的回答更准确且全面, 承认面瘫后遗症可能出现痉挛和异常运动, 符合医学文献和临床实践, 而 ChatGLM3-6B 的回答过于绝对化, 忽略了个体差异和可能的并发症, 这种绝对化的回答很可能误导用户产生对自身情况的错误认知, 并可能带来一些不良后果。相比之下, Med-Chat 在医疗问答上的可靠性和准确性更强。综上所述, 实验结果表明, Med-Chat 在医学问答任务中具有显著的优势, 能够更好地生成与参考答案匹配的高质量文本。

3.5.5 消融实验

为了分析微调、外接知识库和级联去重在构建中文医疗轻问诊模型上的有效性, 进行了三组消融实验进一步研究其中的细节: a) 只进行微调的 ChatGLM3-6B-FT; b) 微调并外接知识库的 ChatGLM3-6B-FT+DB; c) 在微调并外接知识库后添加级联去重模块的 Med-Chat。实验结果如表 3.8 所示, 其中 Y 表示肯定, N 表示否定。

根据表 3.8 所示, 使用中文医疗对话数据集对微调后, 模型的 BLEU 分数从 7.36 提高到 8.16, ROUGE-2 分数提升了 1.37。这说明通过对基模型 ChatGLM3-6B

进行微调，模型能够更深入地理解输入文本的含义和上下文信息，生成更加贴合参考文本的答案，从而具备医疗问答的基础能力。再将医学知识库接入微调后的模型，模型在大部分指标上的结果都有着一定提升，特别是 BLEU 和 ROUGE-2 这两个指标，接入医学知识库后的模型在 BLEU 分数上增加了 1.1，ROUGE-2 增加了 0.54，这表明了结合医学知识对模型生成医学回复的重要性。最后，再额外引入级联去重模块，去除句子中连续重复的字符或词组，而模型在大部分指标上的值均有着下降。模型在 BLEU 指标上降低了 0.44，这是由于 BLEU 更注重生成文本中有多少词组与参考文本中的相同，重复现象使得生成文本与参考文本相同的词组数量增加，导致 BLEU 值偏高。同理，模型在 ROUGE-2 指标上也下降了，由于 ROUGE-2 关注生成文本里与参考文本相同的词组占参考文本的比例，因此降幅较小，仅下降了 0.13。但是模型在 F1 指标上的值有所提升，这表明：虽然添加级联去重模块会影响一些指标，但可以提高生成文本的质量，模型能够生成更专业和更流畅的回答。

表 3.8 消融实验结果

	ChatGLM3-6B	ChatGLM3-6B-FT	ChatGLM3-6B-FT+DB	Med-Chat
微调	N	Y	Y	Y
外接向量知识库	N	N	Y	Y
级联去重	N	N	N	Y
BLEU	7.36	8.16	9.26	8.82
F1-1	36.73	39.07	39.60	39.77
F1-2	10.63	15.53	15.41	15.42
ROUGE-2	12.08	13.45	13.99	13.86

3.5.6 案例分析

表 3.9 描述了一位医生和一位患者之间的对话，其中所有模型的回复都源自这次对话。对话的背景是关于一位患有过敏性鼻炎的患者，之前曾感冒过，感冒好后出现晚上睡觉时鼻塞的情况，感冒时吃了很长一段时间的药。医生的标准回复是肯定患者之前的药物治疗，提醒患者重视过敏性鼻炎可能导致的腺样体肥大，并建议患者继续坚持药物治疗。

Baichuan 的回答未直接提及过敏性鼻炎的药物治疗，而是从症状缓解角度提供了多种非药物建议（如加湿器、热水浴等），与标准回复的核心观点相距较远，相似度最低。Ben Tsao 简洁地确认了过敏性鼻炎的可能性，并建议就医检查，但未涉及药物治疗的持续性，与标准回复的相似度较低。ChatGLM3-6B 详细讨论了

过敏性鼻炎的药物及一些辅助方法，并补充了更多的细节，比如避免过敏原、使用鼻腔冲洗器等，但未肯定持续的药物治疗，也未触及腺样体肥大，与标准回复的相似度较高。Med-Chat 明确认可过敏性鼻炎的可能性及药物治疗的正确性，推荐继续使用指定药物，并建议使用鼻喷剂，与标准回复的主旨最为贴合，虽然未提及腺样体肥大的影响，但与标准回复的相似度最高。综合来看，Med-Chat 的回答最贴合标准回复，充分体现了对药物治疗的肯定以及继续坚持药物治疗的重视，并提供具体建议，其他模型则在不同程度上偏离或补充了标准回复的内容。

表 3.9 案例分析表

患者：睡觉时有鼻塞，呼吸声比较大。前阵子感冒，加上过敏性鼻炎，感冒好了后，没流鼻水也没打喷嚏了，白天完全是正常的。可晚上睡觉时还有些鼻塞，呼吸不怎么顺畅的样子，呼吸声有时会比较大声，有时又正常。感觉是后鼻道分泌物较多引起的。

医生：在睡觉时有鼻塞和呼吸声比较大的情况下，您是否有张着嘴巴呼吸的情况？

患者：没有张嘴。他鼻子就时通时不通的样子。

医生：根据您的描述，这可能是过敏性鼻炎引起的鼻塞。过敏性鼻炎很容易受到一些刺激，比如受凉或者床上尘螨等。建议您口服药物并配合鼻腔喷雾治疗。

患者：之前感冒已经有吃了一比较长时间的药了，孟鲁司特钠，盐酸西替利嗪，盐酸丙卡特罗口服溶液这些。现在是白天都正常了，就睡觉时还会有这情况，而且也有有一两个星期了……

医生：过敏性鼻炎需要长期应用抗过敏药物，您之前的药物治疗是正确的。然而，有时候过敏性鼻炎会导致腺样体肥大，进而影响睡眠质量和注意力集中。为了改善这种情况，建议您重视并继续坚持药物治疗。

Baichuan: 根据您的描述，您可能在睡觉时存在一定程度的鼻塞和呼吸不畅。这可能是由于之前的感冒和过敏性鼻炎导致的后鼻道分泌物增多。虽然您的症状在白天已经有所改善，但夜间睡觉时仍然存在。在这种情况下，您可以尝试以下方法来缓解症状：1. 使用加湿器：在卧室使用加湿器可以增加空气中的湿度，有助于缓解鼻塞和呼吸不畅。2. 热水浴：在热水中加入一些薄荷或桉树精油，然后进行热水浴。这可以帮助打开鼻腔，缓解鼻塞。3. 调整睡姿：尝试侧卧位睡眠，这有助于减轻鼻塞症状。4. 使用鼻腔喷雾：使用非处方鼻腔喷雾（如生理盐水喷雾）可以帮助清洁鼻腔，缓解鼻塞。5. 保持室内空气流通：确保卧室通风良好，以减少过敏原和细菌在室内的浓度。6. 咨询医生：如果以上方法都无法缓解症状，建议您咨询医生，以便得到更专业的建议和治疗。请注意，我不是医生，以上建议仅供参考。如有疑问，请咨询专业医生。

Ben Tsao: 根据病例描述，患者可能患有过敏性鼻炎。过敏性鼻炎的主要症状包括鼻塞、流鼻涕、打喷嚏、鼻痒、流泪等。建议患者到耳鼻喉科就诊，医生可能会进行鼻内窥

续表 3.9 案例分析表

患者：睡觉时有鼻塞，呼吸声比较大。前阵子感冒，加上过敏性鼻炎，感冒好了后，没流鼻水也没打喷嚏了，白天完全是正常的。可晚上睡觉时还有些鼻塞，呼吸不怎么顺畅的样子，呼吸声有时会比较大声，有时又正常。感觉是后鼻道分泌物较多引起的。

医生：在睡觉时有鼻塞和呼吸声比较大的情况下，您是否有张着嘴巴呼吸的情况？

患者：没有张嘴。他鼻子就时通时不通的样子。

医生：根据您的描述，这可能是过敏性鼻炎引起的鼻塞。过敏性鼻炎很容易受到一些刺激，比如受凉或者床上尘螨等。建议您口服药物并配合鼻腔喷雾治疗。

患者：之前感冒已经有吃了一段比较长时间的药了，孟鲁司特钠，盐酸西替利嗪，盐酸丙卡特罗口服溶液这些。现在是白天都正常了，就睡觉时还会有这情况，而且也有的一两个星期了……

医生：过敏性鼻炎需要长期应用抗过敏药物，您之前的药物治疗是正确的。然而，有时候过敏性鼻炎会导致腺样体肥大，进而影响睡眠质量和注意力集中。为了改善这种情况，建议您重视并继续坚持药物治疗。

镜检查、过敏原测试等检查，并根据检查结果制定个性化的治疗方案。

ChatGLM3-6B：您的情况可能是由于过敏性鼻炎导致的后鼻道分泌物增多所引起的。孟鲁司特钠和盐酸西替利嗪是常用的抗组胺药物，可以缓解过敏症状，但往往无法解决鼻塞问题。盐酸丙卡特罗口服溶液是一种 β_2 受体激动剂，可以放松支气管平滑肌，改善气流，但需要配合其他治疗手段。除了药物治疗外，还有一些方法可以帮助缓解鼻塞和呼吸困难，例如：1.保持室内空气湿度适中，避免空气过于干燥。2.使用加湿器或喷雾器增加室内湿度。3.避免过敏原，如花粉、尘螨等。4.改变睡眠姿势，避免鼻塞部位受到压迫。5.使用鼻腔冲洗器清洗鼻腔，减轻鼻塞和过敏症状。如果鼻塞和呼吸困难持续时间较长，严重影响生活质量，建议您前往医院就诊，接受更专业的治疗建议和评估。

Med-Chat：您好，根据您的描述，鼻塞可能是由于过敏性鼻炎引起的。过敏性鼻炎是一种常见的鼻部疾病，会导致鼻塞、鼻涕增多和呼吸不适等症状。建议您继续使用孟鲁司特钠、盐酸西替利嗪和盐酸丙卡特罗口服溶液，这些药物可以帮助缓解过敏症状和改善鼻塞。此外，您可以尝试使用鼻喷剂，它可以帮助减轻鼻塞和鼻塞引起的症状。请注意，如果症状持续或加重，请及时就医咨询专业医生的意见。

3.6 本章小结

本章首先介绍了当前大型语言模型的幻觉现象，其次提出了基于中文医疗对话数据微调的轻问诊模型 Med-Chat。该模型使用医疗对话数据集 DISC-Med-SFT 对通用大语言模型 ChatGLM3-6B 进行指令微调，使其具备医疗问答的对话能力，

并外接医学知识库，为其提供相关医疗知识，缓解其因缺少或遗忘相关知识而产生的幻觉现象，提高该模型的可靠性。同时，针对模型在回答时的重复现象，此模型引入了级联去重机制，去除句子以及字词间的重复，使其能够生成精确、可靠的回答。实验结果表明，Med-Chat 与基线模型 ChatGLM3-6B 相比，在 BLEU 指标和 F1 分数上均取得了提升，通过对模型生成的回答进行分析，对 ChatGLM3-6B 进行调优后得到的中文医疗大模型 Med-Chat 能够生成准确、连贯的回答，具备基础的医学问答能力。

第四章 基于大模型的智慧医疗问答应用设计与实现

在第三章的研究中，通过引入外接知识库，显著增强了通用大语言模型在专业领域的性能。因此，本章聚焦于医疗问答场景，特别针对常见疾病的诊断与咨询需求，构建了一个专门的常见疾病医学知识库，将其作为外接知识库分别整合到中文轻问诊模型 Med-Chat 和通用大语言模型 DeepSeek-R1 中，并根据需要建立了健康问答模块和智能客服模块。同时，本章还探索了基于大模型的智能体在门诊导诊情景上的应用，并将健康问答、智能客服和门诊导诊这三个模块集成到一个基于大模型的智慧医疗问答系统。该系统不仅能够提供精准的医学知识支持，还能在复杂的医疗场景中实现高效、智能的交互服务，为智慧医疗问答的发展提供了技术路径和实践参考。

4.1 引言

随着人工智能技术的快速发展，尤其是大语言模型在自然语言处理领域的广泛应用，智能化的医疗服务已成为提升医疗效率和患者体验的重要手段。传统的医疗服务通常依赖于人工咨询和固定的诊疗流程，往往存在信息传递不及时、资源配置不合理和患者就医体验不佳等问题。这些问题的存在，不仅增加了患者的就医负担，也使得医生和医疗机构在繁重的工作量中面临巨大的压力。随着人口老龄化和慢性病患者数量的不断增加，传统的医疗模式难以满足日益增长的医疗需求，因此，本文构建了一个基于大模型的智慧医疗问答系统，该系统能够通过智能化的问答服务，实现高效的医疗咨询与支持。

该系统基于强大的大语言模型和向量知识库进行设计与实现，旨在通过深度学习和自然语言处理技术，提供精准、个性化的医疗问答服务，进而提升医疗服务的效率和质量。大语言模型的一个显著优势在于，它能够通过上下文理解用户的意图，而不仅仅是根据关键词进行简单匹配。因此，无论患者提问的方式如何，系统都能够智能地理解问题并给出准确的答案，避免了传统搜索引擎中出现的歧义或不相关的答案。向量知识库通过高效的向量化技术，使得系统能够快速从庞大的数据中检索出与用户问题相关的信息，并根据用户的具体情况提供个性化的建议。例如，系统能够根据患者的年龄、性别、病史等因素，为其提供量身定制的健康建议。这种基于数据驱动的智能服务，不仅提升了医疗服务的精准度，还帮助患者在短的时间内能够获得符合需求的答案。

该智慧医疗问答系统由健康问答、智能客服、以及基于智能体的门诊导诊这三个模块组成，分别提供不同的医疗服务。健康问答模块能够为用户提供有关健

健康管理、疾病预防和生活方式建议等方面的智能化解答。智能客服模块可以为用户提供 24 小时的在线咨询服务，随时回答用户关于就诊流程、科室位置、药品信息等方面的问题，为日常医疗服务提供自动化支持。门诊导诊模块通过分析用户的症状和健康状况，为其推荐合适的科室和医生，帮助用户快速找到合适的诊疗服务。此外，门诊导诊模块还可以根据科室和医生的工作情况，为用户提供最新的挂号信息，提升整体的就诊效率。

用户通过该智慧医疗问答系统，可以获得关于健康管理、疾病预防、诊疗建议等方面的智能问答服务。系统通过深度理解用户提出的问题以及医学知识库的辅助，能够帮助用户快速找到所需的医学信息，并指导其科学就医。不论是日常的健康管理建议，还是针对特定疾病的预防措施与治疗方案，系统都能提供专业的解答。这种智能化的问答服务，不仅提高了信息获取的效率，也使得患者能够更加科学地进行自我管理和就医决策，避免了不必要的困惑和误诊。

4.2 系统架构设计

4.2.1 总体架构

该智慧医疗问答系统基于大模型和向量知识库构建，旨在通过先进的人工智能技术提升医疗服务的效率和质量。整个系统由健康问答、智能客服和基于智能体的门诊导诊三个模块组成，系统架构可以分为数据层、应用层和交互层三个主要部分，如图 4-1 所示。




图 4-1 系统总体架构图

数据层是系统的基础支撑部分，负责处理、存储和管理大量的医学数据，确保系统能够高效、准确地存取医学信息，支持应用层的各个模块正常运转。数据层存储疾病、症状、治疗方案、药物信息、临床指南以及用户的健康数据等，为系统提供准确的基础数据支持。此外，数据层还负责向量知识库的构建与管理，通过对医学文本进行嵌入处理，将其转化为高维向量表示，以支持后续的相似度搜索与推理，从而帮助系统快速响应用户的查询。数据层还可以根据系统的需求，持续更新和优化医学知识库，确保其内容的时效性和准确性。通过不断的学习和数据反馈，数据层可以进一步提升系统的智能性和精准度，满足应用层的需求，为整个系统的高效运作提供数据保障。

应用层通过对数据层的知识和信息进行处理、整合与应用，实现了系统的智能化功能。应用层包含健康问答、智能客服和门诊导诊这三个模块，它们分别承担不同的任务，并协同工作以提升系统的智能化和服务效率。健康问答模块利用大模型的语义理解和向量知识库的知识检索能力，提供相关医学知识的精准回答；智能客服模块面向患者和家属，提供日常医疗服务的自动化支持；门诊导诊模块通过分析用户的症状、病史和需求，智能地推荐合适的科室和医生。系统通过大模型和向量知识库的高效协作，结合动态优化能力，为用户提供个性化、智能化的医疗服务。

交互层作为系统与用户进行直接沟通的桥梁，承担着实现人与系统之间互动的关键角色。交互层通过图形界面、语音交互等工具为用户提供友好的交互方式，确保用户能够便捷、高效地获取信息和服务，提升了整体的用户体验和系统的智能化水平。

4.2.2 功能模块设计

该智慧医疗问答系统的应用层包含三个核心功能模块：健康问答、智能客服和门诊导诊。这些功能模块不仅能够提供个性化的健康建议、辅助诊疗决策、解答常见的医疗问题，还能够智能引导用户的就诊流程，极大地提升了医疗服务的便捷性、准确性和用户体验。接下来，本节将对这些功能模块进行详细介绍。

健康问答模块利用大模型和向量知识库，为用户提供精准的健康咨询服务，如图 4-2 所示。用户可以提出关于疾病症状、治疗方法、药物使用等方面的问题，系统根据医学知识库中的信息，结合大模型的语言理解能力，生成符合用户需求的回答。基于大模型的自然语言处理能力和专业的医学知识，健康问答模块能够理解复杂的医疗问题并提供个性化的健康建议。




图 4-2 健康问答模块设计图

智能客服模块则是为日常医疗服务的自动化提供支持，其结构与健康问答模块类似，但知识库的内容有着不同，智能客服模块所用的知识库主要包含医院就诊流程、各科诊室所在的位置、药品信息等内容。通过界面交互的方式，系统可以解答用户关于就诊流程、诊室位置和药品查询等常见问题。智能客服模块的自动化服务不仅减轻了医院工作人员的负担，还优化了用户的就医体验。

门诊导诊模块利用智能体（Agent）的自主决策和实时学习能力，为患者提供精准、个性化的就诊指导。大模型都有着其能力边界，几乎不可能实现所有任务的通用能力，但 Agent 可以通过让大模型学会与其他模型、工具甚至环境进行交互，实现能力的扩展。Agent 的核心功能可以归纳为三个步骤的循环：感知（Perception）、规划（Planning）和行动（Action），如图 4-3 所示。感知是指 Agent 从环境中收集信息并从中提取相关知识的能力，规划是指 Agent 为了某一目标而做出的决策过程，行动是指基于环境和规划做出的动作。其中，Policy 是 Agent 做出行动的核心决策，而行动又通过观察（Observation）成为进一步感知的前提和基础，形成自主地闭环学习过程。这一过程就像马克思主义的实践论：“认识从实践开始，经过实践得到了理论的认识，再回到实践中去。”




图 4-3 Agent 决策流程

基于智能体构建的门诊导诊模块通过智能体的感知、规划和行动三个循环步骤，为用户提供智能化的就诊引导，具体流程如图 4-4 所示。首先，在感知阶段，智能体通过大模型收集并理解用户的症状信息，识别出最可能的就诊科室。接着，进入规划阶段，智能体从知识库中提取该科室的位置信息及医生的实时安排，并结合用户的需求和科室资源进行处理与分析，确保推荐的科室和医生的可用性与适配性。最后，在行动阶段，智能体将所有处理后的科室位置信息和医生信息进行汇总，并优化输出，提供患者最准确、便捷的就诊路径和医生推荐，提升就医效率和体验。




图 4-4 门诊导诊模块流程图

4.3 构建常见疾病医学知识库

4.3.1 数据收集与处理

虽然通用大语言模型已具备自然语言处理能力，能够生成符合语法规则的流畅文本，但在医疗咨询场景应用时仍面临着显著的知识鸿沟与领域适应性瓶颈。为突破通用大语言模型在医疗垂直领域的能力边界，有必要向其注入充足且专业的常见医疗知识，从而使其能够更好地适应医疗场景。因此，本文基于默沙东诊疗手册（专业版）以及近百篇临床指南，构建了一个涵盖常见疾病的医学知识库。该知识库涵盖了 17 种医学主题、近 2000 种疾病和功能障碍的病因及诊疗机制等相关信息。各种医学主题及其包含的相关疾病示例如表 4.1 所示。

表 4.1 知识库涵盖的医学主题及相关疾病示例

医学主题	疾病示例
耳鼻咽喉疾病	慢性外耳道炎、喉炎、非过敏性鼻炎等
肺部疾病	急性支气管炎、哮喘、肺炎等
妇产科学	乳腺癌、宫颈癌、阴道炎等
肝脏及胆道疾病	急性胆囊炎、肝炎、酒精性肝病等
肌肉骨骼及结缔组织疾病	滑囊炎、肌腱炎、腱鞘炎等
口腔疾病	龋齿、牙髓炎、磨牙症等
精神疾病	神经性厌食症、创伤后应激障碍等
泌尿生殖系统疾病	慢性肾脏病、急性肾损伤、前列腺炎等
皮肤科疾病	玫瑰痤疮、毛囊炎、脂溢性皮炎等
免疫学及过敏性疾病	过敏性鼻炎、慢性肉芽肿病等
消化道疾病	肠胃炎、胰腺炎、吸收不良综合征等
心血管疾病	心内膜炎、高血压、静脉曲张等
眼部疾病	白内障、青光眼、泪囊炎等
营养性疾病	肥胖、维生素 A 缺乏症等
传染病	手足口病、疱疹性咽炎、支气管炎等
儿科学	婴儿痉挛症、儿童尿路感染等
内分泌及代谢稳定	糖尿病、呼吸性碱中毒等

本文采用 Python 爬虫技术，从默沙东诊疗手册（专业版）网站中自动化获取有关疾病及其诊疗机制的相关信息。具体而言，使用 requests 和 BeautifulSoup 等库对该网站进行数据抓取，实现了对页面内容的结构化解析，分别获取各医学主题包含的内容，最终生成 Word 文档。之后再对文档内的数据进行清洗，去除其中的冗余信息和无关内容，确保仅保留疾病描述、治疗方案和诊疗技术等核心信息。最后将处理后的 Word 文档转为 PDF 文档，并使用这些文档构建向量知识库。

4.3.2 知识库的更新与维护

若常见疾病医学知识库中存在医疗知识不准确或信息陈旧的情况，这会为大模型提供错误的医学知识，影响其专业性和准确性。此时，应及时修正或更新知识库，移除不正确或过时的医疗信息，相应的操作和效果如图 4-5 中所示。通过上传知识文档作为构建知识库的知识来源，当需要移除错误或过时的医疗信息时，可选中相应文档进行删除；当有需要更新的知识时，可以删除相应的知识文档再

重新上传更新后的知识文档。




图 4-5 知识库的更新与维护

4. 4 系统模块功能实现

从医疗数据的私密性角度出发，本文对基于大模型的智慧医疗问答系统进行本地化部署。利用 AnythingLLM 工具在本地构建和运行知识库，实现数据的本地化处理，并对不同模块进行分区管理，保障各模块的数据隐私性和安全性。同时，利用 Ollama 运行本地部署的大模型，保证用户的数据和对话记录不会被其他地方存储和访问，增强了数据的安全性和隐私性。此外，在该系统中可以根据需要，选择使用中文轻问诊模型 Med-Chat 或大语言模型 DeepSeek-R1 作为底层大模型，本节所展示的系统问答效果均是以 DeepSeek-R1 作为底层大模型生成的回答。

该系统目前被部署在内网上，域名为 <https://anythingllm.tsic.top/>，可以测试的管理员账号名为“asdf”，密码是“123456.”，需要加入内网才能访问，网页的登录界面如图 4-6 所示。




图 4-6 用户登录界面

4.4.1 健康问答功能模块

该模块使用的知识库为 4.2 节构建的常见疾病医学知识库，后台上传知识库的操作如图 4-7 所示。界面左侧负责知识文档的上传，可以通过简易的拖拽的方式上传知识文档；界面右侧负责根据上传的知识文档构建向量知识库，点击“Save and Embed”组件，使用嵌入模型对知识文档进行向量化，生成向量知识库。




图 4-7 知识库上传及向量化的界面

登录成功后，用户可以向模型咨询医疗问题。这里以“如何检查耳部疾病”这个问题为例，展示该模块的问答能力。在回答用户的问题时，模型会先根据用户的问题查询知识库，获取相关的医学文本，然后根据医学文本回答相应问题，图 4-8 展示了模型根据上下文回答用户问题的思维链，图 4-9 展示了外接知识库

的回答效果。




图 4-8 外接知识库的模型回复前的思维链

大模型思维链（Chain of Thought, CoT）是一种引导大型语言模型进行复杂推理的技术，通过模仿人类的分步思考过程，要求模型将问题分解为中间推理步骤，如假设、推导等，逐步生成答案。

检查耳部疾病需结合多维度评估，具体步骤包括：

01. 症状与体格检查
- 评估耳痛、听力损失、耳漏、耳鸣及眩晕等核心症状。
 - 检查耳部及邻近结构（如鼻、鼻窦、牙齿、颞下颌关节），排除牵涉痛。
 - 观察眼球震颤，并检查颅神经功能（尤其是第 V、Ⅶ、Ⅷ、Ⅸ、X 对神经）。
02. 听力检测
- 听力图测试：针对听力异常或耳鸣患者，评估听觉敏感度及类型（传导性/感音神经性）。
03. 前庭功能评估
- 视频眼震电图（VNG）或眼震电图（ENG）：
 - VNG通过红外外视镜记录眼球运动，检测自发性、凝视性或位置性眼震。
 - ENG使用电极记录，分析前庭系统对冷热刺激的反应（冷热试验），识别单侧前庭功能减退。
 - 姿势描记术：通过压力传感平台评估平衡控制（睁眼/闭眼、平台移动/静止），判断前庭系统对平衡的贡献。
04. 影像学检查
- 颞骨CT（增强或非增强）：适用于外伤、慢性感染或结构异常。
 - 钆增强脑部MRI：排查内听道病变（如听神经瘤），尤其针对不明原因听力损失、眩晕或面瘫。
05. 特殊适应症
- 外伤、慢性耳部感染、面瘫或顽固性耳痛患者需优先影像学评估。

通过以上综合手段，可定位病因（耳源性或全身性），并指导后续治疗。

图 4-9 外接知识库的部分回答

从图 4-8、图 4-10 的思维链来看，外接知识库的模型，通过参考默沙东手册的相关医学文本，其思维的专业性和准确度远远高于不带知识库的模型。图 4-9

和图 4-11 更突显了外接知识库的模型在医疗问答时回答的准确度和可靠性。




图 4-10 没有知识库的模型回复前的思维链

检查耳部疾病通常需结合自我观察和医学检查，以下是常见方法：

一、自我初步观察

01. **症状识别**：注意耳痛、瘙痒、流脓、听力下降、耳鸣、耳闷、眩晕或平衡异常。
02. **外观检查**：用干净棉签轻触耳廓，若疼痛加剧可能有炎症；肉眼可见耳道红肿、异常分泌物需警惕感染。
03. **简易听力测试**：单耳听钟表声或摩擦手指声，对比两侧听力差异。

二、专业医学检查

01. **耳镜检查**：医生使用耳镜观察外耳道和鼓膜，检查红肿、异物、鼓膜穿孔或积液。
02. **听力评估**：

- **音叉试验**：判断传导性/感音神经性听力损失
- **纯音测听**：精确检测各频率听力阈值
- **声导抗测试**：评估中耳功能及鼓膜活动度

03. 影像学检查：

- **CT扫描**：检查中耳、内耳结构异常（如胆脂瘤）
- **MRI**：排查听神经瘤等神经病变

04. **实验室检测**：取耳分泌物进行细菌/真菌培养
05. **前庭功能测试**（针对眩晕）：眼震电图、冷热试验等

注意事项

- 避免自行掏耳，棉签可能将耵聍推入深处
- 突发剧烈耳痛、听力骤降或伴面瘫需急诊处理

图 4-11 没有知识库的问答效果

4.4.2 智能客服功能模块

智能客服助手可以 24 小时应答，回答用户的问题，如解答科室位置、就诊流程和药品查询等。如图 4-12 所示，用户询问安徽医科大学第一附属医院泌尿外科所在的位置，智能客服模块通过查询包含各科诊室信息、就诊流程等内容的基础知识库，获取相关诊室信息，生成回答。




图 4-12 智能客服模块可视化界面

4.4.3 门诊导诊功能模块

基于智能体构建的门诊导诊模块能够根据用户的输入信息，如症状、病史、既往病情等，查询常见疾病医学知识库，通过实时分析和推理，推荐最适合的科室；之后再结合诊室信息知识库，提供当前的科室信息和诊疗安排。如图 4-13 所示，当用户输入肺部不舒服的症状时，该模块可以根据症状判断是否需要就诊呼吸内科，并给出科室所在的院区位置，同时给出近一周的科室医生安排表和就诊的注意事项。

根据您的肺部不适症状，推荐您前往【呼吸与危重症医学科（呼吸内科）】就诊，科室位于绩溪路院区。以下是该科室未来一周（3月23日-29日）的医生排班信息：

3月23日（星期日）

上午：王勇医生、杨晓春医生

下午：张燕医生

3月24日（星期一）

上午：丁佩山医生、王炯医生、刘荣玉医生

下午：朱钟鸣医生、孙耕耘医生

3月25日（星期二）

上午：李永怀医生、徐爱晖医生、胡先纬医生

下午：许锐医生、范晓云医生

3月26日（星期三）

上午：桂淑玉医生、杨晓春医生、费广鹤医生

下午：张妍蓓医生、董佳慧医生

3月27日（星期四）

上午：张妍蓓医生、王瑞医生、汪伟民医生

下午：尤青海医生、汪辉云医生

3月28日（星期五）

上午：杨志仁医生、杨晓春医生、汪伟民医生

下午：费黎明医生、祝清清医生

3月29日（星期六）

上午：朱莹莹医生、闫雪波医生

下午：周群医生、武沛佩医生

注意事项：

1. 每天分上午（一般 8:00-12:00）和下午（14:00-17:30）两个时段
2. 同一时段有多个医生坐诊时，可任选一位挂号
3. 周六周日正常接诊

如需预约或了解医生专长，可随时咨询。建议优先选择上午号源，就诊前避免进食过饱。

图 4-13 门诊导诊模块的回答内容

4.5 本章小结

本章的主要内容是开发了一个基于大模型的智能问答系统，并将其部署在内网上，以确保敏感的医疗数据不外流，保障用户的隐私。该系统主要由健康问答、智能客服和门诊导诊这三个核心模块组成。健康问答模块利用大模型的自然语言处理能力和具有专业医学知识的向量知识库，为用户提供提供个性化的健康咨询服务；智能客服模块为用户提供 24 小时的在线咨询服务，解答用户关于科室位置、就诊流程和药品信息等方面的问题；门诊导诊模块通过分析用户的症状、病史和

需求，为其推荐合适的科室和就诊建议。此外，该系统将这三个模块进行分区管理，确保各模块的数据隐私性和安全性。

第五章 总结与展望

5.1 总结

医疗问答大模型作为人工智能与医疗健康深度融合的突破口，其重要性体现在三个核心维度：资源普惠化、诊疗精准化与服务智能化。在医疗资源分布不均的现实背景下，模型通过整合权威医学知识库与海量临床数据，能够为基层医疗机构提供三甲医院级的知识支持。其价值更在于突破传统医疗信息服务的碎片化局限。随着多模态技术演进，未来将融合 CT 影像分析、临床诊断数据解析、体检报告分析等能力，真正实现“千人千面”的精准医疗。本文围绕医疗大模型的关键技术优化与应用开发展开系统性研究，取得以下核心成果：

（1）针对大型语言模型在医疗场景中存在的训练成本高、知识不全面和回答冗余的问题，本文对基模型 ChatGLM3-6B 进行了一系列的优化，主要包括特定领域微调，知识库检索增强以及级联去重这三部分工作。首先使用医疗数据 DISC-Med-SFT 数据集对选择的通用大模型 ChatGLM3-6B 进行医疗问答领域微调，通过动态调整权重提升其对医学术语的理解能力；其次，整合 DISC-Med-SFT 数据集、临床指南、药品说明书等医学数据构建医学知识库，并使用检索增强生成技术将其接入微调后的大语言模型；最后，引入级联去重机制，去除模型回答中的重复噪声，使其生成流畅、可靠的回答。

（2）基于大型语言模型开发了医疗问答系统，该系统主要由健康问答、智能客服和门诊导诊这三个核心模块构成。该系统基于强大的大语言模型和向量知识库进行设计与实现，旨在通过深度学习和自然语言处理技术，提供精准、个性化的医疗问答服务，进而提升医疗服务的效率和质量。该系统使用本地化模型服务框架作为底层支撑平台，支持 Med-Chat 和 DeepSeek-R1 等大语言模型的本地化部署，确保医疗数据的隐私性和安全性。并通过添加知识库，为大语言模型具备准确、丰富的医学知识提供了保障，进而开发了健康问答模块和智能客服模块，以满足多样化的医疗服务需求。之后还深入探讨了智能体技术在门诊导诊场景中的应用，通过智能分析用户的症状和需求，为用户推荐合适的就诊科室和相关注意事项。

5.2 展望

本文探讨了如何将通用大语言模型应用在医疗问答场景上，通过利用微调和外接知识库为大模型注入专业的医学领域知识，提升通用大语言模型在医疗问答上的性能；并构建了一个基于大模型的智慧医疗问答系统，为用户提供健康咨询、

门诊导诊等智能服务。但仍存在一些不足之处，并有许多可以进一步研究和改进的空间。以下是未来可持续探索和改进的几个方向：

（1）本文提出的方法主要解决如何让通用大语言模型更好地适应医疗场景，关键在于将专业的医学知识注入模型，提升模型在医疗问答中的准确率。但在真实的临床场景下，面对复杂病例时，模型仅仅能回答准确还不够，还需要像医生一样具备分析病情和解决实际问题的能力。因此，未来的研究方向需要着重考虑：在训练医疗大模型时，如何加入更多的含有复杂信息的真实病例，帮助模型建立清晰的推理步骤，同时通过不同的评估指标，比如诊断的逻辑性、治疗方案的合理性等，来全面评估模型的实际应用能力。

（2）医学知识库在本文的智慧医疗问答系统中有着重要位置，为了保持医疗问答系统的准确性和可靠性，为医学知识库添加一个动态更新机制也至关重要。该机制可以定期验证和评估已有知识的有效性，自动淘汰过时的内容并判断哪些新信息需要优先更新到知识库中，帮助维护人员决定更新的顺序。这一动态更新机制不仅提高了知识库的时效性，还能大幅提升医疗问答系统在实际应用中的准确性与可靠性，确保其能够为用户提供更专业、更靠谱的智能服务。

（3）随着医疗领域对精准诊断需求的不断提升，医疗领域将更加依赖多模态数据集来优化诊断过程，构建多模态数据集将成为未来医学研究和智慧医疗辅助系统发展的重要方向。同时，多模态数据集包含了多种类型的数据，如 CT 图像、影像记录和电子病历等，能够为疾病诊断提供更为全面的信息，帮助医生进行更加精准和个性化的治疗决策。因此，如何有效融合这些不同形式的数据也成为需要解决的关键问题。

参考文献

- [1] 许晋军,苏新宁.信息搜索引擎综述[J].计算机系统应用,1999,(04):22-24.
- [2] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [3] Roumeliotis I K, Tselikas D N. ChatGPT and Open-AI Models: A Preliminary Review[J]. Future Internet, 2023, 15(6):192.
- [4] Touvron H, Lavril T, Izacard G, et al. Llama: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.
- [5] Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.
- [6] GLM T, Zeng A, Xu B, et al. Chatglm: A family of large language models from glm-130b to glm-4 all tools[J]. arXiv preprint arXiv:2406.12793, 2024.
- [7] Yang A, Xiao B, Wang B, et al. Baichuan 2: Open large-scale language models[J]. arXiv preprint arXiv:2309.10305, 2023.
- [8] 李佳丽.面向儿科常见疾病的智能问答技术研究与应用[D].贵州大学,2024.
- [9] 肖革新,陈善吉,王博远,等.医疗大模型的应用现状与展望[J].中国数字医学,2025,20(02):39-45.
- [10] 白培发,黄宗浩,王奕.大模型在智慧医院的应用研究综述[J].计算机应用与软件,2024,41(07):1-5.
- [11] 医联.医联发布国内首款医疗大语言模型 MedGPT[EB/OL]. <https://www.medlinker.com/index/xinwenzhongxin/1199>, 2023-07-19.
- [12] Zhu W, Yue W, Wang X. ShenNong-TCM: A Traditional Chinese medicine large language model [EB/OL]. <https://github.com/michael-wzhu/ShenNong-TCM-LLM>, 2023-06-25.
- [13] 咎红英, 窦华溢, 贾玉祥, 等.基于多来源文本的中文医学知识图谱的构建[J].郑州大学学报 (理学版), 2020,52(2):45-51.
- [14] Wang H, Liu C, Xi N, et al. Huatuo: Tuning llama model with chinese medical knowledge[J].arXiv preprint arXiv:2304.06975, 2023.
- [15] Xin Y, Dong X. Sunsimiao: Chinese Medicine LLM[EB/OL]. <https://github.com/thomas-yanxin/Sunsimiao>, 2023-07-06.
- [16] Yao C, CMKRG, DendiHust X. QiZhenGPT: An Open Source Chinese Medical Large Language Model[EB/OL]. <https://github.com/CMKRG/QiZhenGPT>, 2023-06-27.
- [17] Cui Y, Yang Z, Yao X. Efficient and effective text encoding for chinese llama and alpaca[J].arXiv preprint arXiv:2304.08177, 2023.

- [18] Chen Y, Wang Z, Xing X, et al. Bianque: Balancing the questioning and suggestion ability of health llms with multi-turn health conversations polished by chatgpt[J]. arXiv preprint arXiv:2310.15896, 2023.
- [19] Chen Y, Xing X, Lin J, et al. SoulChat: Improving LLMs' empathy, listening, and comfort abilities through fine-tuning with multi-turn empathy conversations[J]. arXiv preprint arXiv:2311.00273, 2023.
- [20] Wang G, Yang G, Du Z, et al. ClinicalGPT: large language models finetuned with diverse medical data and comprehensive evaluation[J]. arXiv preprint arXiv:2306.09968, 2023.
- [21] Bai Y, Jones A, Ndousse K, et al. Training a helpful and harmless assistant with reinforcement learning from human feedback[J]. arXiv preprint arXiv:2204.05862, 2022.
- [22] Yang S, Zhao H, Zhu S, et al. Zhongjiing: Enhancing the chinese medical capabilities of large language model through expert feedback and real-world multi-turn dialogue[C]. In Proceedings of the AAAI conference on artificial intelligence. 2024, 38(17):19368-19376.
- [23] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]. In Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies. 2019, 1:4171-4186.
- [24] Lee J, Yoon W, Kim S, et al. BioBERT: a pre-trained biomedical language representation model for biomedical text mining[J]. Bioinformatics, 2020, 36(4):1234-1240.
- [25] Huang K, Altosaar J, Ranganath R. Clinicalbert: Modeling clinical notes and predicting hospital readmission[J]. arXiv preprint arXiv:1904.05342, 2019.
- [26] Gu Y, Tinn R, Cheng H, et al. Domain-specific language model pretraining for biomedical natural language processing[J]. ACM Transactions on Computing for Healthcare (HEALTH), 2021, 3(1):1-23.
- [27] Raffel C, Shazeer N, Roberts A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of machine learning research, 2020, 21(140):1-67.
- [28] Lu Q, Dou D, Nguyen T. ClinicalT5: A generative language model for clinical text[C]. In Findings of the Association for Computational Linguistics: EMNLP 2022. 2022:5436-5443.
- [29] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33:1877-1901.
- [30] Chowdhery A, Narang S, Devlin J, et al. Palm: Scaling language modeling with pathways[J]. Journal of Machine Learning Research, 2023, 24(240):1-113.
- [31] Singhal K, Azizi S, Tu T, et al. Large language models encode clinical knowledge[J]. Nature, 2023, 620(7972):172-180.

- [32] Chung H W, Hou L, Longpre S, et al. Scaling instruction-finetuned language models[J]. Journal of Machine Learning Research, 2024, 25(70):1-53.
- [33] Singhal K, Tu T, Gottweis J, et al. Toward expert-level medical question answering with large language models[J]. Nature Medicine, 2025:1-8.
- [34] Li Y, Li Z, Zhang K, et al. Chatdoctor: A medical chat model fine-tuned on a large language model meta-ai (llama) using medical domain knowledge[J]. Cureus, 2023, 15(6).
- [35] Shu C, Chen B, Liu F, et al. Visual Med-Alpaca: A Parameter-Efficient Biomedical LLM with Visual Capabilities[EB/OL]. <https://github.com/cambridgeltl/visual-med-alpaca>, 2023-04-19.
- [36] Bengio Y, Ducharme R, Vincent P, et al. A neural probabilistic language model[J]. Journal of machine learning research, 2003, 3(Feb):1137-1155.
- [37] Mikolov T, Karafiát M, Burget L, et al. Recurrent neural network based language model[C]. In Proceedings of the interspeech. 2010, 2(3):1045-1048.
- [38] Sundermeyer M, Schlüter R, Ney H. Lstm neural networks for language modeling[C]. In Proceedings of the interspeech. 2012:194-197.
- [39] Radford A. Improving language understanding by generative pre-training[J]. 2018.
- [40] Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners[J]. OpenAI blog, 2019,1(8):9.
- [41] Achiam J, Adler S, Agarwal S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.
- [42] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. Advances in neural information processing systems, 2022, 35:27730-27744.
- [43] Bridle J. Training stochastic model recognition algorithms as networks can lead to maximum mutual information estimation of parameters[J]. Advances in neural information processing systems, 1989, 2.
- [44] Mikolov T, Sutskever I, Chen K, et al. Distributed representations of words and phrases and their compositionality[J]. Advances in neural information processing systems, 2013, 26.
- [45] Pennington J, Socher R, Manning C D. Glove: Global vectors for word representation[C]. In Proceedings of the 2014 conference on empirical methods in natural language processing. 2014:1532-1543.
- [46] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. In Proceedings of the IEEE conference on computer vision and pattern recognition. 2016:770-778.
- [47] Ba J L, Kiros J R, Hinton G E. Layer normalization[J]. arXiv preprint arXiv:1607.06450, 2016.
- [48] Glorot X, Bordes A, Bengio Y. Deep sparse rectifier neural networks[C]. In Proceedings of the

- fourteenth international conference on artificial intelligence and statistics. 2011:315-323.
- [49] Biswas S S. Role of chat gpt in public health[J]. Annals of biomedical engineering, 2023, 51(5):868-869.
- [50] Biswas S S. Potential use of chat gpt in global warming[J]. Annals of biomedical engineering, 2023, 51(6):1126-1127.
- [51] Kalla D, Smith N, Samaah F, et al. Study and analysis of chat GPT and its impact on different fields of study[J]. International journal of innovative science and research technology, 2023, 8(3):827-833.
- [52] Haman M, Školník M. Using ChatGPT to conduct a literature review[J]. Accountability in research, 2024, 31(8):1244-1246.
- [53] Lo C K. What is the impact of ChatGPT on education? A rapid review of the literature[J]. Education sciences, 2023, 13(4):410.
- [54] Du Z, Qian Y, Liu X, et al. GLM: General Language Model Pretraining with Autoregressive Blank Infilling[C]. In Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. 2022:320-335.
- [55] Wang L, Ma C, Feng X, et al. A survey on large language model based autonomous agents[J]. Frontiers of Computer Science, 2024, 18(6):186345.
- [56] Bi X, Chen D, Chen G, et al. Deepseek llm: Scaling open-source language models with longtermism[J]. arXiv preprint arXiv:2401.02954, 2024.
- [57] Jacobs R A, Jordan M I, Nowlan S J, et al. Adaptive mixtures of local experts[J]. Neural computation, 1991, 3(1):79-87.
- [58] Liu A, Feng B, Xue B, et al. Deepseek-v3 technical report[J]. arXiv preprint arXiv:2412.19437, 2024.
- [59] Dai D, Deng C, Zhao C, et al. Deepseekmoe: Towards ultimate expert specialization in mixture-of-experts language models[J]. arXiv preprint arXiv:2401.06066, 2024.
- [60] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.
- [61] Guo D, Zhu Q, Yang D, et al. DeepSeek-Coder: When the Large Language Model Meets Programming--The Rise of Code Intelligence[J]. arXiv preprint arXiv:2401.14196, 2024.
- [62] Kotsis K T. ChatGPT and DeepSeek Evaluate One Another for Science Education[J]. EIKI Journal of Effective Teaching Methods, 2025, 3(1):98-102.
- [63] Chen J, Zhang Q. DeepSeek reshaping healthcare in China's tertiary hospitals[J]. arXiv preprint arXiv:2502.16732, 2025.
- [64] Lialin V, Deshpande V, Rumshisky A. Scaling down to scale up: A guide to parameter-efficient

- fine-tuning[J]. arXiv preprint arXiv:2303.15647, 2023.
- [65] Houlisby N, Giurciu A, Jastrzebski S, et al. Parameter-efficient transfer learning for NLP[C]. In Proceedings of the 36th international conference on machine learning. 2019:2790-2799.
- [66] Li X L, Liang P. Prefix-tuning: Optimizing continuous prompts for generation[J]. arXiv preprint arXiv:2101.00190, 2021.
- [67] Zaken E B, Ravfogel S, Goldberg Y. Bitfit: Simple parameter-efficient fine-tuning for transformer-based masked language-models[J]. arXiv preprint arXiv:2106.10199, 2021.
- [68] Hu E J, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models[J]. ICLR, 2022, 1(2):3.
- [69] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A survey[J]. arXiv preprint arXiv:2312.10997, 2023, 2.
- [70] Huang R, Huang J, Yang D, et al. Make-an-audio: Text-to-audio generation with prompt-enhanced diffusion models[C]. In Proceedings of the 40th international Conference on Machine Learning. 2023:13916-13932.
- [71] Xi Z, Chen W, Guo X, et al. The rise and potential of large language model based agents: A survey[J]. Science China Information Sciences, 2025, 68(2):121101.
- [72] Le Scao T, Fan A, Akiki C, et al. Bloom: A 176b-parameter open-access multilingual language model[J]. HAL open science, 2023.
- [73] Ji Z, Lee N, Frieske R, et al. Survey of hallucination in natural language generation[J]. ACM computing surveys, 2023, 55(12):1-38.
- [74] Bao Z, Chen W, Xiao S, et al. Disc-medllm: Bridging general large language models and real-world medical consultation[J]. arXiv preprint arXiv:2308.14346, 2023.
- [75] Zeng G, Yang W, Ju Z, et al. MedDialog: Large-scale medical dialogue datasets[C]. In Proceedings of the 2020 conference on empirical methods in natural language processing. 2020:9241-9250.
- [76] Zhang S, Zhang X, Wang H, et al. Multi-scale attentive interaction networks for chinese medical question answer selection[J]. IEEE Access, 2018, 6:74061-74071.
- [77] Papineni K, Roukos S, Ward T, et al. Bleu: a method for automatic evaluation of machine translation[C]. In Proceedings of the 40th annual meeting of the Association for Computational Linguistics. 2002:311-318.
- [78] Lin C Y. Rouge: A package for automatic evaluation of summaries[C]. In Proceedings of the text summarization branches out. 2004:74-81.